# Guía docente — Clase 1 · Neural Networks: Deep Learning (UIDE)

Oct 15, 2026 · @Andres O

## Resumen del kit

La semana 1 se dicta con un solo deck de 78 láminas (viernes 1–41, sábado 42–78), tres notebooks ejecutados y verificados, un caso PBL ecuatoriano sintético y la lectura + encuesta de tendencia. Cada lámina trae en sus notas del orador el guion docente, las respuestas y los errores típicos; las láminas de práctica (32, 40 y 66) traen el QR al notebook en Colab y la tabla de ejemplo resuelto y tarea de cada sección.

| Material | Para quién | Dónde se usa |
|---|---|---|
| Deck · Clase 1 — Fundamentos de redes neuronales (78 láminas, exportable a .pptx/PDF) | Docente (proyección) | Viernes láminas 1–41 · sábado 42–78 |
| NB01_viernes_tu_primera_neurona.ipynb | Estudiantes | Viernes: práctica 1 (secciones 1–5) y práctica 2 (secciones 6–8) |
| NB02_sabado_tu_primera_red.ipynb | Estudiantes | Sábado: práctica 3 (partes A–G) |
| NB03_miniproyecto_cooperativa_starter.ipynb + cooperativa_ficticia_mora.csv | Grupos | Trabajo en salas y entregable (70 pts) |
| NB03_miniproyecto_cooperativa_SOLUCIONARIO.ipynb | Solo docente | Calificación y dudas en salas |
| Apuntes teóricos · Clase 1 | Estudiantes | Lectura previa y estudio para el test |
| Enunciado del mini-proyecto · Clase 1 | Grupos | Canvas, tarea del componente práctico |
| Lectura de tendencia · Clase 1 | Estudiantes | Canvas, desde el 19-oct |

| Material | Para quién | Dónde se usa |
|---|---|---|
| Encuesta de tendencia (sección de esta guía) | Docente → Canvas | Cargar antes del 19-oct |

Enlaces: Apuntes teóricos · Clase 1 · Enunciado del mini-proyecto · Lectura de tendencia. Para Canvas, cada doc se exporta a PDF o Word desde su menú.

Todos los notebooks corren de principio a fin en Python 3 con TensorFlow 2.21 / Keras 3.15 (probado); en Colab no requieren instalación. NB02 tarda ~1 min y el solucionario de NB03 ~2 min en CPU.

**Página para estudiantes (repositorio):** github.com/AndresOrdonez369/EIG-DeepLearning-Week1. Es la carpeta 1_pagina_web: inicio, proyectos (NB01, NB02, NB03 en Colab y los datos), guía de estudio, pre-quiz y quiz final, y el material en PDF. Se publica con GitHub Pages en andresordonez369.github.io/EIG-DeepLearning-Week1. Las soluciones, las slides y esta guía están en 2_profesor y no van al repo.

**Guía docente y apuntes (HTML).** En tu carpeta, `2_profesor/Guia_docente.html` amplía este plan con los apuntes con rigor de cada bloque, las preguntas que te pueden hacer, las claves de las tareas y quizzes, y el seguimiento de grupos; los resultados de los quizzes se ven en 2_profesor/Resultados_quiz.html. Este documento queda para la logística, la encuesta de tendencia y los pendientes.

## Checklist de la semana

Lo crítico antes del viernes es tener Canvas cargado (lectura, encuesta, test, sílabo corregido, enunciado) y las salas de Teams creadas.

### Antes del inicio

- [ ] Oct 19, 2026 Lectura y encuesta de tendencia de la Clase 1 visibles en Canvas
- [ ] Oct 20, 2026 Sílabo corregido y publicado (docente, firma, tutorías, erratas "Tranfer", "Coordinador Académica", URL de Nielsen `chap1.html`)
- [ ] Banco del test de la Clase 1 verificado en Canvas; ajustes reportados a coordinación
- [ ] La carpeta 1_pagina_web subida al repo de GitHub con GitHub Pages activado, y el enlace de la página publicado en Canvas (no subir nada de 2_profesor)
- [ ] Enunciado del mini-proyecto publicado como tarea grupal (70 pts) con fecha de cierre
- [ ] Reunión con la tutora (Alejandra García) y salas de grupos pequeños creadas en Teams

### Semana en curso

- [ ] Oct 21, 2026 Apertura de la Clase 1 en Canvas
- [ ] Oct 23, 2026 Sesión 1 (18:00–20:00): grabación verificada; al cerrar, "Finalizar reunión para todos"
- [ ] Oct 24, 2026 Sesión 2 (08:00–12:00): grabación verificada; salas abiertas a las 10:40
- [ ] Oct 27, 2026 Cierre de la Clase 1 (test, encuesta, entregable): confirmar hora exacta en Canvas

### Después del cierre

- [ ] Oct 29, 2026 Video de conclusiones de tendencia de la Clase 1 (1–3 min) con los resultados de la encuesta
- [ ] Oct 30, 2026 Retroalimentación y calificación de la Clase 1 en Canvas (por criterio, solo contenido de deep learning)

## Plan del viernes 23-oct (18:00–20:00)

El viernes va de cero a la receta del deep learning: qué son la IA, el machine learning y el deep learning; la neurona como comité de crédito que traza una línea; el perceptrón y su límite XOR; la pérdida y el descenso de gradiente. Dos prácticas cortas con el NB01 fijan las ideas. El guion detallado de cada lámina está en sus notas del orador.

| Hora | Bloque | Láminas | Qué debe quedar | Pregunta para lanzar |
|---|---|---|---|---|
| 18:00–18:07 | Apertura y encuadre | 1–5 | Grabación verificada; perfil del grupo; objetivos y evaluación 70/20/10 | ¿Qué problema de su trabajo resolverían con datos? |
| 18:07–18:13 | Pre-quiz | 6 | Todos jugaron; puntajes en el chat | ¿Qué pregunta les pareció más difícil? |
| 18:13–18:28 | 01 · IA, ML y DL | 7–14 | IA ⊃ ML ⊃ DL; reglas vs. ejemplos; cuándo conviene el DL | En una palabra, ¿qué es la IA? |
| 18:28–18:50 | 02 · La neurona | 15–24 | z = 2.81 a mano; la línea; la sigmoide; pausa activa | Si el comité se vuelve más exigente, ¿qué número cambia? |

| Hora | Bloque | Láminas | Qué debe quedar | Pregunta para lanzar |
|---|---|---|---|---|
| 18:50–19:05 | 03 · El perceptrón | 25–31 | Regla; corrección −0.30 → +2.70; XOR; cómo abrir Colab | ¿Alguien puede trazar una línea que separe XOR? |
| 19:05–19:25 | Práctica 1 · NB01 secciones 1–5 | 32 | Colab funcionando en todos; T1–T5 | ¿Por qué una corrección no bastó en la T3? |
| 19:25–19:45 | 04 · Pérdida y gradiente | 33–39 | MSE, BCE, el Cotopaxi, la pendiente, η | ¿Cómo bajarían del Cotopaxi con neblina? |
| 19:45–19:55 | Práctica 2 · NB01 secciones 6–8 | 40 | T6–T7 en clase; T8 y Mini-reto 1 en casa | ¿Qué pasa con η = 1.1? |
| 19:55–20:00 | Cierre | 41 | La receta con fórmulas; tareas para el sábado | Del 1 al 5, ¿podrían explicar el descenso de gradiente? |

**Si el tiempo aprieta:** recorta las láminas 12–13 (tipos de aprendizaje y por qué ahora) y la 29 (garantía) a un minuto cada una, y deja la sección 8 del NB01 como tarea; nunca recortes la práctica 1, porque es donde todos dejan Colab funcionando.

**Materiales abiertos antes de empezar:** deck en modo presentación, NB01 en Colab ya ejecutado una vez (para no esperar la carga) y playground.tensorflow.org abierto para el final del bloque 04.

## Plan del sábado 24-oct (08:00–12:00)

El sábado tiene un objetivo innegociable: que cada grupo salga con su mini-proyecto corriendo en Colab. El ejemplo 2-2-1 con números (láminas 51–57) es el corazón teórico; si hay que recortar, se recorta el bloque 07 (láminas 60–62), no las salas.

| Hora | Bloque | Láminas | Qué debe quedar | Pregunta para lanzar |
|---|---|---|---|---|
| 08:00–08:10 | Apertura y repaso | 42–44 | El viernes explicado por ellos | ¿Qué problema nos quedó pendiente? |
| 08:10–08:30 | 05 · De una neurona a una red | 45–49 | Capas; XOR con dos neuronas; contar parámetros | ¿Cuántos parámetros tiene una red 3-4-1? |

| Hora | Bloque | Láminas | Qué debe quedar | Pregunta para lanzar |
|---|---|---|---|---|
| 08:30–09:10 | 06 · Retropropagación | 50–58 | Forward 2-2-1; la culpa; engranajes; un paso 56 % → 65 %; cuatro reglas; pausa activa | Si la culpa de un peso es negativa, ¿sube o baja? |
| 09:10–09:20 | Pausa | — | — | — |
| 09:20–09:40 | 07 · Entrenar bien | 59–63 | Tres trampas; lotes; optimizadores; receta | ¿Por qué no iniciar los pesos en cero? |
| 09:40–10:15 | 08 · Keras + práctica 3 | 64–66 | Construir, compilar, entrenar; NB02 A, B, E, F y Mini-reto 2 | ¿Qué hace `fit()` por dentro? |
| 10:15–10:25 | Pausa | — | — | — |
| 10:25–10:40 | 09 · Consigna del mini-proyecto | 67–72 | El caso, la ruta del NB03, la trampa del 87 %, entregable y rúbrica | ¿Cuál es su métrica y por qué no la exactitud? |
| 10:40–11:35 | Trabajo en salas | 73 | NB03: secciones 1–5 y 7 y un primer experimento (8); la 6 se termina en casa. Rota ~8 min por sala | (preguntas por sala) |
| 11:35–11:47 | Socialización | 74 | 3 grupos × 3 min + retro de contenido | ¿Qué decisión discutieron? |
| 11:47–11:57 | Quiz final | 75 | Todos jugaron; comparan con el pre-quiz | ¿Qué pregunta les costó más? |
| 11:57–12:00 | Cierre | 76–78 | Entregas del martes 27; guía de estudio; adelanto de la Clase 2 | Del 1 al 5, ¿podrían explicar cómo aprende una red? |

**Rotación por salas (40 min):** unos 8 minutos por grupo. En cada sala pregunta: qué datos usan, cuál es su métrica, si escalaron después de partir, y qué les falta para tener el MLP en Keras entrenando.

**Materiales abiertos antes de empezar:** deck, NB02 ya ejecutado una vez en Colab, NB03 solucionario en otra pestaña (no compartir pantalla con él), salas de Teams creadas.

## Errores típicos y cómo responder

Los errores de esta semana son casi siempre de dimensiones, de escalado o de métrica, no de teoría profunda. Responde primero con una pregunta que los lleve al error.

| Error típico | Cómo se ve | Respuesta sugerida |
|---|---|---|
| Confundir δ con el gradiente de los pesos | "δ es ∂ℒ/∂W" | δ = ∂ℒ/∂z; el gradiente de W es δ por la entrada (BP3) |
| Olvidar φ′ en BP2 | Gradient check falla por un factor ~4 con sigmoide | "¿Por qué función pasó z en el forward?" |
| Etiquetas {0,1} en el perceptrón | El perceptrón nunca corrige un tipo de error | Pasar a {−1,+1} o usar (y − ŷ) |
| Escalar con todo el dataset | AUC de validación optimista | Ajustar `StandardScaler` solo con train: fuga de información |
| Sin escalar entradas | Pérdida NaN o estancada | El ingreso en USD domina la suma: estandarizar |
| Accuracy como única métrica | "87 % de exactitud" con un modelo inútil | ROC-AUC, PR-AUC y recall en un umbral de negocio |
| Formas (N,) vs (N, 1) | Broadcasting silencioso: pérdida rara | Imprimir `.shape` de y y de ŷ antes de restar |
| Gradient check "falla" con ReLU | Error ~$10^{-3}$ con sesgos en 0 | z = 0 exacto en una capa muerta; sesgos pequeños ≠ 0 |
| η alto con SGD | Curva que sube o explota | Bajar η × 10; recordar $\eta < 2/\lambda_{max}$ |
| Mirar el test para decidir | Elegir modelo o umbral con test | Todo se decide con validación; test una sola vez |

| Error típico | Cómo se ve | Respuesta sugerida |
|---|---|---|
| Antropomorfizar | "La red piensa como el cerebro" | Es una composición de funciones; la biología fue inspiración |

**Conceptos que conviene repetir:** el gradiente es información local; el teorema de aproximación universal habla de existencia, no de aprendizaje; en datos tabulares un MLP no siempre supera a una buena regresión logística.

## Clave docente del caso de la cooperativa

El dataset sintético tiene un techo teórico de ROC-AUC ≈ 0.91 (usando la probabilidad real del generador); un MLP bien hecho llega a ≈ 0.87 y la regresión logística a ≈ 0.85. No compartir esta sección con estudiantes.

**Datos:** 8 000 créditos, semilla 2026, prevalencia de mora 12.7 %; partición estratificada 4 800 / 1 600 / 1 600 (train / val / test); 28 entradas tras el preprocesamiento (10 numéricas + 18 one-hot).

**Efectos escondidos a propósito** (lo que un buen análisis exploratorio debería descubrir):

| Efecto | Forma | Por qué importa para el modelo |
|---|---|---|
| Carga de la cuota (cuota / ingreso) | Casi nula hasta 0.32 y luego sube fuerte, saturando | No lineal; la variable no viene dada: hay que construirla o aprenderla |
| Garante × carga | Garante reduce el riesgo si la carga < 0.45, lo aumenta si ⩾ 0.45 | Interacción tipo XOR (lámina 47) |
| Agricultura × plazo ⩽ 12 meses | Riesgo mucho mayor (cosecha vs. cuota mensual) | Interacción categórica × numérica |
| Edad | Forma de U, mínimo cerca de 44 años | No monótona |
| Antigüedad como socio | Protege, saturando después de ~3 años | Rendimientos decrecientes |

| Efecto | Forma | Por qué importa para el modelo |
|---|---|---|
| Atrasos previos | Suben el riesgo, con tope a partir de 2 | Saturación |
| Ahorro / ingreso | Protege (logarítmico) | Monotónico suave |
| Zona rural sin agricultura; sin créditos previos | Efectos pequeños positivos | Ruido estructurado |

**Resultados de referencia del solucionario** (validación, umbral 0.5):

| Modelo | ROC-AUC | PR-AUC | Accuracy |
|---|---|---|---|
| Siempre "no mora" | 0.500 | 0.127 | 0.873 |
| Regresión logística | 0.848 | 0.529 | 0.890 |
| Regresión logística + cuota/ingreso | 0.859 | — | — |
| Perceptrón (pocket) | 0.835 | 0.475 | 0.889 |
| MLP NumPy 32-16 (SGD + momentum) | 0.873 | 0.562 | 0.897 |
| MLP Keras 32-16 (Adam) | 0.869 | 0.589 | 0.898 |

En test, con un umbral por modelo elegido en validación para recall ⩾ 70 %: MLP Keras ROC-AUC 0.870, recall 0.645 y precisión 0.430; regresión logística ROC-AUC 0.860, recall 0.714 y precisión 0.398. En la grilla de experimentos (25 épocas) Adam fue robusto en las 4 combinaciones (0.868–0.878) y SGD sin momentum con $\eta = 10^{-3}$ quedó en 0.65–0.72: buen material para la discusión.

**Qué premiar al calificar:** que el grupo detecte al menos una interacción o no linealidad en la exploración, que no use accuracy como métrica principal y que interprete la brecha MLP vs. logística con honestidad (≈ 2 puntos de AUC).

## Encuesta de tendencia · Clase 1

Diez preguntas (8–10 minutos) sobre la lectura "Más allá de Adam"; se responden con la lectura y criterio propio. Cargar en Canvas como encuesta o quiz no calificado por respuesta; los 10 puntos se asignan según el criterio que confirme la tutora.

Escala Likert para P3–P6: 1 Totalmente en desacuerdo · 2 En desacuerdo · 3 Neutral · 4 De acuerdo · 5 Totalmente de acuerdo.

**P1 · Opción múltiple · comprensión.** Según Wen et al. (2025), cuando todos los optimizadores se ajustan con el mismo cuidado, la ventaja de los optimizadores matriciales sobre AdamW…

- crece a medida que el modelo es más grande.
- baja de alrededor de 1.4× (0.1B parámetros) a alrededor de 1.1× (1.2B parámetros). ✅
- desaparece: AdamW gana en todos los tamaños.
- se mantiene en alrededor de 2× en todos los tamaños.

**P2 · Opción múltiple · comprensión.** ¿Qué relación tiene Muon con lo visto en la Clase 1?

- Es descenso de gradiente con momentum cuya actualización se ortogonaliza para las matrices de pesos ocultas. ✅
- Reemplaza a la retropropagación por un método sin gradientes.
- Es una nueva función de activación que evita el desvanecimiento del gradiente.
- Es un método de inicialización de pesos que sustituye a He y Xavier.

**P3 · Likert · opinión.** Las mejoras que reporta un optimizador nuevo dependen más del cuidado con que se ajustó la línea base que del algoritmo en sí.

**P4 · Likert · opinión.** Para la mayoría de organizaciones en Ecuador, mejorar la calidad de los datos rinde más que cambiar de optimizador o de modelo.

**P5 · Likert · opinión.** Los laboratorios que entrenan los modelos más grandes deberían publicar el cómputo y las emisiones de su entrenamiento.

**P6 · Likert · opinión.** América Latina debe entrenar sus propios modelos fundacionales (como Latam-GPT) en lugar de solo adaptar modelos extranjeros.

**P7 · Opción múltiple · experiencia.** En su organización o sector, ¿cuál es hoy la principal barrera para entrenar modelos de deep learning?

- Cómputo (GPU) y costos de nube
- Datos: cantidad, calidad o acceso
- Talento especializado
- Regulación y privacidad
- Falta de casos de negocio claros
- No trabajo con modelos actualmente

**P8 · Opción múltiple · aplicación al proyecto.** Para el proyecto de titulación de su grupo, ¿qué palanca cree que mejorará más el desempeño del modelo?

- Mejor optimizador o ajuste de hiperparámetros
- Más datos o datos de mejor calidad
- Una arquitectura más adecuada al tipo de dato
- Más cómputo (más épocas, modelos más grandes)
- Otro (especifique)

**P9 · Abierta (máx. 100 palabras).** Si tuviera USD 5 000 para mejorar un modelo de su proyecto, ¿los invertiría en cómputo, en datos o en personas? Argumente con al menos una evidencia de la lectura.

**P10 · Abierta (máx. 100 palabras).** Un proveedor afirma que su nuevo optimizador entrena "2× más rápido". ¿Qué preguntas le haría antes de creerle?

**Qué voy a mirar en los resultados (para el video del 29-oct)**

1. H1: al menos 60 % responde 4–5 en P3 después de leer Wen et al.; si no, vale la pena explicar mejor qué es una comparación justa.
2. H2: en P7 la barrera "Datos" supera a "Cómputo", coherente con P4 y P8.
3. H3: P6 sale polarizada (muchos 1–2 y 4–5): buen tema para el debate de ética e identidad cultural de la semana 3.

## Pendientes por confirmar

Seis decisiones dependen de la tutora o de coordinación; el material ya funciona con supuestos razonables marcados como provisionales.

- [ ] Hora exacta de cierre del entregable, el test y la encuesta (supuesto: martes 27-oct, según el cronograma)
- [ ] Rúbrica institucional del componente práctico (en uso: la provisional de 70 pts del enunciado)
- [ ] Cómo se califican los 10 pts de tendencia (¿participación completa = 10?)
- [ ] Si el banco del test de la Clase 1 ya existe en Canvas o se crea desde cero
- [ ] Plantilla de proyecto vigente y si esta asignatura es PBL 1, 2 o 3 del bloque
- [ ] Si el docente puede editar el sílabo heredado o solo publicarlo