Mini-proyecto PBL · Clase 1 — Una línea base neuronal para su proyecto

Oct 15, 2026 · @Andres O

Neural Networks: Deep Learning · UIDE · Componente práctico de la Clase 1 · Grupal · 70 puntos · Cierre: Oct 27, 2026 (hora exacta en Canvas).

Propósito

Su grupo construirá y comparará, sobre los datos de su proyecto de titulación, modelos que van desde una neurona hasta un perceptrón multicapa, y justificará cada decisión con la teoría de la semana. El resultado es una **línea base neuronal**: el punto de comparación sobre el que construirán las arquitecturas de la Clase 2 y las técnicas de la Clase 3.

- **Resultado de aprendizaje 1 del sílabo:** comprender la estructura y el entrenamiento de redes neuronales.
- **Mínimos técnicos de la semana:** implementación de un perceptrón, retropropagación en un dataset y un MLP en Keras/TensorFlow con optimización y ajuste de parámetros.
- **Competencia de pensamiento crítico:** justificar la elección de modelos, reflexionar sobre los resultados y proponer mejoras.

Insumos

Usen los datos de su proyecto de titulación. Si aún no los tienen, o si sus datos son imágenes, texto o series (cuyas arquitecturas llegan en la Clase 2), usen el caso de respaldo.

Caso de respaldo: Cooperativa de Ahorro y Crédito "Valle Andino" (ficticia). La cooperativa atiende socios en 10 provincias del Ecuador (comercio, agricultura, servicios, transporte, artesanía, manufactura) y quiere estimar la probabilidad de que un socio caiga en **mora de más de 30 días** para acompañarlo antes del atraso. Los datos son 100 % sintéticos: 8 000 créditos, 13 variables y la etiqueta `mora_30d` (12.7 % de casos positivos).

Archivo (en Canvas)	Contenido
`cooperativa_ficticia_mora.csv`	Datos del caso de respaldo

Archivo (en Canvas)	Contenido
`NB03_miniproyecto_cooperativa_starter.ipynb`	Notebook base: carga, exploración, partición sin fuga, líneas base y las partes A–D con espacios `TODO`
`NB02_sabado_tu_primera_red.ipynb`	Referencia del taller: forward y backward a mano, gradient check, GradientTape y Keras en 3 pasos

Grupos con datos propios: reemplacen solo la sección 1 del notebook (carga) y conserven la estructura del resto.

Qué deben hacer

Cuatro partes técnicas, en este orden, todas sobre la misma partición de datos (entrenamiento / validación / prueba, estratificada y con semilla fija).

0. **Preparación.** Exploración mínima con 3 hallazgos que impliquen algo para el modelo (no linealidades, interacciones, desbalance). Escalado y codificación ajustados **solo** con entrenamiento. Líneas base: predecir siempre la clase mayoritaria y regresión logística.
1. **Parte A · Perceptrón desde cero (NumPy).** Implementen la regla de Rosenblatt y la variante *pocket*. Grafiquen los errores por época y expliquen, con el teorema de Novikoff, por qué converge o no en sus datos.
2. **Parte B · MLP con retropropagación desde cero (NumPy).** Implementen el backward (BP1–BP4) de un MLP con al menos una capa oculta. Aprueben el *gradient check* (error relativo $< 10^{-6}$) y entrenen con mini-batches.
3. **Parte C · MLP en Keras.** Arquitectura, activación, inicialización y optimizador justificados; curvas de entrenamiento y validación; métricas adecuadas al problema (en clases desbalanceadas, ROC-AUC y PR-AUC además de accuracy).
4. **Parte D · Experimentos de optimización.** Diseño factorial de optimizador (SGD, SGD + momentum, Adam) × tasa de aprendizaje × tamaño de batch, más **una dimensión propia** (ancho, profundidad, activación o inicialización). Elijan el modelo final con validación y evalúenlo en prueba **una sola vez**.

Cada integrante debe poder explicar cada línea del backward de la Parte B: en la socialización o la retroalimentación se puede pedir a cualquiera.

Qué entregan

Un envío por grupo en Canvas con dos archivos.

1 · Notebook `.ipynb`. Se ejecuta completo en Colab sin errores (Entorno de ejecución → Ejecutar todo), con las salidas visibles, semilla fija y comentarios del código en inglés.

2 · Informe PDF de 4 a 6 páginas, con esta estructura:

1. Problema, datos y métrica elegida (y por qué esa métrica).
2. Hallazgos de la exploración que influyeron en el modelo.
3. Tabla comparativa: líneas base, perceptrón, MLP NumPy, MLP Keras (validación) y el modelo final (prueba).
4. Experimentos de la Parte D: tabla o mapa de calor, y qué factor pesó más.
5. Justificación de cada decisión de modelado con la teoría de la semana.
6. Conexión con el proyecto de titulación y próximos pasos para la Clase 2.

La retroalimentación de contenido (deep learning) la da el docente; formato, estructura y normas APA los revisa la coordinación de Titulación.

Rúbrica (provisional)

Esta rúbrica se usa mientras no llegue la institucional; si coordinación la envía antes del cierre, se avisará por Canvas.

Criterio	Pts	Excelente (100 %)	Aceptable (~60 %)	Insuficiente (~20 %)
Implementación técnica	25	Perceptrón, MLP NumPy con gradient check < 10^{-6} y MLP Keras; el notebook corre completo y es reproducible	Funciona con fallas menores o alguna parte incompleta	No ejecuta o tiene errores conceptuales (por ejemplo, fuga de información)

Criterio	Pts	Excelente (100 %)	Aceptable (~60 %)	Insuficiente (~20 %)
Experimentación y análisis	15	Métricas adecuadas al desbalance; diseño factorial completo; selección con validación y prueba usada una vez	Métricas básicas o experimentos incompletos	Sin evidencia experimental
Justificación de decisiones	15	Cada decisión (arquitectura, activación, inicialización, optimizador, umbral) argumentada con teoría y datos	Justificación parcial	Ausente
Integración con el proyecto	10	Avance claro y coherente hacia el proyecto de titulación	Conexión débil	Trabajo aislado del proyecto
Comunicación del informe	5	Claro, preciso, figuras legibles	Comprensible	Confuso
Total	**70**			

Preguntas guía y recursos

Respondan en el informe al menos cuatro de estas preguntas; son las que distinguen un informe excelente.

1. ¿Cuánto mejora el MLP sobre la regresión logística? ¿Es una mejora relevante para el negocio o ruido? Repitan con 3 semillas y reporten media ± desviación.
2. Construyan a mano una variable que crean importante (en el caso de la cooperativa, cuota / ingreso) y reentrenen la logística. ¿Se cierra la brecha? ¿Qué dice eso sobre diseñar variables frente a aprenderlas?

3. ¿Por qué el perceptrón converge o no en sus datos? Relácionenlo con el teorema de Novikoff.
4. ¿Qué umbral de decisión usarían si cada falso negativo y cada falso positivo tienen costos distintos? Planteen la función de costo (en la cooperativa: una llamada preventiva cuesta poco; un crédito en mora, mucho).
5. Adelanto de ética (Clase 3): ¿hay variables que actúen como sustitutas de grupos vulnerables (por ejemplo, provincia o zona)? ¿Cómo lo verificarían?
6. ¿Qué parte de este pipeline reutilizarán tal cual en la Clase 2 y qué cambiará con su tipo de dato?

Recursos: apuntes teóricos de la Clase 1, notebooks NB01 y NB02, Nielsen (2015) capítulos 1–2, y el capítulo de MLP de *Dive into Deep Learning* (d2l.ai).