Más allá de Adam: ¿mejor algoritmo o más cómputo?

Oct 15, 2026 · @Andres O

Lectura de tendencia · Clase 1 · Neural Networks: Deep Learning · Maestría en Ciencia de Datos y Máquinas de Aprendizaje · UIDE · Tiempo de lectura: ~12 min

Por qué importa esta semana

Esta semana aprendemos que entrenar una red es bajar por una superficie de pérdida con descenso de gradiente, y que el optimizador (SGD, momentum, Adam) decide cuánto cuesta llegar al valle. En 2025 y 2026 los grandes laboratorios empezaron a reemplazar a AdamW por optimizadores nuevos como Muon, con promesas de hasta el doble de eficiencia. Al mismo tiempo, estudios independientes mostraron que, medidas con justicia, esas ventajas se encogen.

La pregunta de fondo es muy práctica para un científico de datos en Ecuador: con cómputo escaso y caro, ¿conviene invertir en mejores algoritmos, en más cómputo o en mejores datos?

Contexto: de SGD a Adam y AdamW

Casi todos los modelos de los últimos diez años se entrenaron con alguna variante de Adam. Adam (Kingma y Ba, 2015) combina dos ideas que vemos en la Clase 1: una media móvil del gradiente (momentum, la dirección) y una media móvil del gradiente al cuadrado (la escala de cada parámetro). AdamW separa el *weight decay* del paso adaptativo y se volvió el estándar para modelos grandes.

Dos rasgos de Adam importan para esta lectura:

- **Trata cada parámetro por separado.** Ajusta el paso número por número, sin mirar la estructura de las matrices de pesos.
- **Cuesta memoria.** Guarda dos vectores extra (m y s) del tamaño del modelo; en un modelo de miles de millones de parámetros eso son gigabytes adicionales en GPU.

La nueva ola de optimizadores ataca justamente el primer punto: tratar una matriz de pesos como matriz, no como una lista de números.

La tendencia: Muon y los optimizadores matriciales

Muon pasó en un año de un experimento de comunidad a entrenar modelos de un billón de parámetros. Es, en esencia, descenso de gradiente con momentum, el mismo de la Clase 1, con un paso extra: antes de aplicar la actualización de cada matriz de pesos oculta, la "ortogonaliza" (mediante iteraciones de Newton–Schulz) para que empuje con la misma fuerza en todas las direcciones. Los demás parámetros (embeddings, capa de salida, sesgos) se siguen entrenando con AdamW (Jordan, s. f.).

Analogía. Adam ajusta cada tornillo de una estructura por separado; Muon ajusta la pieza completa para que no se tuerza hacia un solo lado.

La evidencia que impulsó la tendencia, en orden cronológico:

Fecha	Quién	Qué reportó
s. f.	Jordan (repositorio Muon)	Récord de velocidad para alcanzar GPT-2 small mejorado 1.35×; desempeño de GPT-2 XL con USD 175 de cómputo
Feb 2025	Moonshot AI (Liu et al., 2025)	Con weight decay y escala de actualización ajustada, ~2× de eficiencia frente a AdamW (≈ 52 % de los FLOPs); modelo Moonlight 3B/16B MoE con 5.7 billones de tokens
Jul 2025	Moonshot AI (Kimi Team, 2025)	Kimi K2: 1 billón de parámetros (32 mil millones activos), 15.5 billones de tokens con MuonClip y "cero picos de pérdida"
Ago 2025	Zhipu AI y Tsinghua (GLM-4.5 Team, 2025)	GLM-4.5 (355B totales, 32B activos): Muon "acelera la convergencia y tolera batches más grandes"
Jun 2026	PyTorch / DeepSpeed (Wang et al., 2026)	Muon guarda un solo buffer de momentum frente a dos de Adam; en su medición la memoria pico por GPU bajó de 34.5 a 31.4 GiB (9 %), un ahorro que ellos mismos llaman "modesto"

Nota de unidades: en español, 1 billón = 10^{12} (en inglés, *trillion*).

El contrapeso: comparaciones justas y el costo del cómputo

Cuando todos los optimizadores se ajustan con el mismo cuidado, la ventaja de los nuevos sobre AdamW es real pero mucho menor que la anunciada, y se reduce a medida que el modelo crece.

- **Wen, Hall, Ma y Liang (2025), Stanford.** Compararon diez optimizadores en cuatro escalas (0.1B a 1.2B parámetros), ajustando a cada uno por separado. Concluyen que la aceleración real sobre una línea base bien ajustada "es menor que la reportada": la de los optimizadores matriciales baja de 1.4× (0.1B) a solo 1.1× (1.2B). Advierten que los hiperparámetros óptimos de un optimizador pueden ser malos para otro.
- **Semenov, Pagliardini y Jaggi (2025), EPFL.** Señalan que cada artículo usa un protocolo distinto, lo que impide comparar. En su banco de pruebas, AdEMAMix fue el mejor de forma consistente; además, lo que gana en carreras cortas puede no ganar en entrenamientos largos, donde AdamW recorta la distancia.
- **AlgoPerf (Kasimbeg et al., 2025).** Una competencia con reglas comunes (18 envíos de 10 equipos) midió tiempo real de reloj. Ganó Distributed Shampoo, otro método que usa la estructura matricial, y en la categoría sin ajuste manual ganó una variante de AdamW (*Schedule-Free*).

Mientras tanto, la escala manda. El *AI Index 2026* de Stanford reporta que:

Indicador	Valor
Crecimiento de la capacidad global de cómputo para IA	3.3× por año desde 2022 (17.1 millones de equivalentes H100)
Emisiones estimadas del entrenamiento de Grok 4	72 816 t de CO_2 equivalente (DeepSeek V3: ≈ 597 t)
Potencia de centros de datos de IA	29.6 GW, comparable al pico de demanda del estado de Nueva York
Costo del cómputo en GPU desde 2006	Cayó más de 99 %

El mismo informe registra dos señales en direcciones opuestas: los sistemas más intensivos en cómputo de OpenAI, Anthropic y Google ya no publican código de entrenamiento, número de parámetros, tamaño de datos ni duración; y OLMo 3.1 Think 32B, con casi 90 veces menos parámetros que Grok 4, logra resultados comparables en varios benchmarks gracias a poda, deduplicación y curaduría de datos. Para dimensionar:

Epoch AI estimó que el cómputo de entrenamiento de los modelos notables creció entre 4 y 5 veces por año de 2010 a 2024. Frente a eso, un optimizador que ahorra 1.1–2× es una mejora valiosa, pero no cambia el orden de magnitud.

Casos de aplicación

Tres casos muestran la misma tensión desde la industria, la investigación y nuestra región.

1 · Industria: Kimi K2 (Moonshot AI, 2025). El optimizador fue una decisión de ingeniería, no un detalle: con un billón de parámetros, un pico de pérdida puede arruinar semanas de cómputo. Su variante MuonClip agrega un recorte (*QK-clip*) para estabilizar la atención, y el equipo reporta 15.5 billones de tokens sin picos de pérdida. La lección para la Clase 1: la estabilidad del descenso de gradiente vale tanto como su velocidad.

2 · Investigación: AlgoPerf (ICLR 2025). En vez de que cada autor elija su propia comparación, AlgoPerf fija tareas, presupuesto y reglas de ajuste, y mide tiempo real hasta alcanzar una meta. Es el equivalente científico de una carrera con el mismo terreno para todos: lo que en clase llamamos comparar con una línea base bien ajustada.

3 · América Latina y Ecuador: Latam-GPT (2026). Liderado por el Centro Nacional de Inteligencia Artificial de Chile (CENIA), se lanzó el 10 de febrero de 2026: 70 mil millones de parámetros, construido sobre Llama 3.1 y entrenado en la nube de AWS, con alianzas en 15 países (DPL News, 2026). Según una columna en El Comercio, usó más de 300 mil millones de tokens, costó alrededor de USD 550 000 aportados por CENIA y CAF, requiere al menos 40 GB de VRAM para correrlo localmente, y Ecuador participó a través de varios actores, entre ellos el laboratorio "Alan Turing" de la Escuela Politécnica Nacional; el autor declara que participó en actividades del proyecto (Benalcázar, 2026). La decisión de partir de Llama 3.1 en lugar de entrenar desde cero es, en sí misma, una respuesta al dilema de esta lectura: con presupuesto acotado, se reutiliza cómputo ajeno y se invierte en datos propios. Un análisis de Tech Policy Press sostiene que su valor realista está en construir capacidades regionales y atender nichos como las lenguas indígenas, más que en competir con las grandes plataformas (Rivero, 2026).

Tensiones y debates

Cuatro preguntas siguen abiertas y no tienen una respuesta única; la encuesta de esta semana te pide tomar postura.

Tensión	Una postura	La otra postura
Promesa vs. medición justa	Muon y similares ya probaron su valor en modelos de un billón de parámetros; ~2× es enorme a esa escala.	Con ajuste justo la ganancia ronda 1.1× a 1.2B parámetros; buena parte de la "mejora" era una línea base mal ajustada.
Algoritmo vs. escala vs. datos	Mejores optimizadores son la forma más barata de ganar eficiencia.	El cómputo crece 3–5× por año y la curaduría de datos (OLMo 3.1) rinde más que cambiar de optimizador.
Transparencia	Los laboratorios abiertos (Moonshot, Zhipu) publican sus optimizadores y permiten replicar.	Los sistemas más costosos ya no informan cómputo, datos ni duración: no se puede auditar su costo real.
Soberanía y costo ambiental	La región necesita modelos propios que entiendan su contexto y sus lenguas (Latam-GPT).	Con cómputo escaso y alto costo ambiental, adaptar modelos existentes es más responsable que entrenar desde cero.

Una pista para pensar como científico de datos: ninguna de estas posturas se defiende con adjetivos. Se defiende con una comparación justa, una métrica clara y el costo de obtenerla.

Conexión con tu proyecto de titulación

En el mini-proyecto de esta semana comparan SGD, momentum y Adam sobre sus propios datos: es una versión pequeña del mismo debate. Usen estas preguntas para el informe:

1. ¿Su comparación de optimizadores es justa? ¿Cada uno tuvo la misma oportunidad de ajustar su tasa de aprendizaje?
2. Si su mejor optimizador gana por 1–2 puntos de AUC, ¿es una diferencia mayor que la variación entre semillas?
3. Con el cómputo que tienen (Colab gratuito), ¿qué rendiría más: otro optimizador, más épocas o limpiar y enriquecer los datos?
4. Si su modelo llegara a producción en una organización ecuatoriana, ¿qué costo de cómputo y de energía deberían reportar?

Para profundizar (opcional)

- AI Index 2026, capítulo 1: investigación, cómputo y emisiones, con gráficos.
- Wen et al. (2025): el resumen y la figura principal bastan para entender cómo se hace una comparación justa.
- Repositorio de Muon: documenta el algoritmo y cómo combinarlo con AdamW; se entiende con lo visto en la Clase 1.

Referencias

Benalcázar, M. E. (2026, 21 de febrero). *Latam-GPT es el equivalente latinoamericano a ChatGPT*. El Comercio. https://www.elcomercio.com/opinion/latam-gpt-equivalente-latinoamericano-chatgpt-marco-benelcazar-columnista/

DPL News. (2026, 10 de febrero). *Lanzan Latam-GPT, el primer modelo de lenguaje de IA colaborativo para América Latina*. https://dplnews.com/latam-gpt-modelo-de-lenguaje-de-ia-america-latina/

GLM-4.5 Team. (2025). *GLM-4.5: Agentic, reasoning, and coding (ARC) foundation models* [Preprint]. arXiv. https://arxiv.org/abs/2508.06471

Jordan, K. (s. f.). *Muon: An optimizer for the hidden layers of neural networks* [Repositorio de GitHub]. https://github.com/KellerJordan/Muon

Kasimbeg, P., Schneider, F., Eschenhagen, R., Bae, J., Sastry, C. S., Saroufim, M., Feng, B., Wright, L., Yang, E. Z., Nado, Z., Medapati, S., Hennig, P., Rabbat, M., y Dahl, G. E. (2025). Accelerating neural network training: An analysis of the AlgoPerf competition. En *International Conference on Learning Representations (ICLR 2025)*. https://arxiv.org/abs/2502.15015

Kimi Team. (2025). *Kimi K2: Open agentic intelligence* [Preprint]. arXiv. https://arxiv.org/abs/2507.20534

Kingma, D. P., y Ba, J. (2015). Adam: A method for stochastic optimization. En *International Conference on Learning Representations (ICLR 2015)*. https://arxiv.org/abs/1412.6980

Liu, J., Su, J., Yao, X., Jiang, Z., Lai, G., Du, Y., Qin, Y., Xu, W., Lu, E., Yan, J., y otros. (2025). *Muon is scalable for LLM training* [Preprint]. arXiv. https://arxiv.org/abs/2502.16982

Loshchilov, I., y Hutter, F. (2019). Decoupled weight decay regularization. En *International Conference on Learning Representations (ICLR 2019)*. https://arxiv.org/abs/1711.05101

Rivero, E. (2026, 2 de marzo). *LatamGPT navigates the gap between regional aspiration and market realities*. Tech Policy Press. https://www.techpolicy.press/latamgpt-navigates-the-gap-between-regional-aspiration-and-market-realities

Semenov, A., Pagliardini, M., y Jaggi, M. (2025). *Benchmarking optimizers for large language model pretraining* [Preprint]. arXiv. https://arxiv.org/abs/2509.01440

Sevilla, J., y Roldán, E. (2024, 28 de mayo). *Training compute of frontier AI models grows by 4-5x per year*. Epoch AI. https://epoch.ai/blog/training-compute-of-frontier-ai-models-grows-by-4-5x-per-year

Stanford Institute for Human-Centered Artificial Intelligence. (2026). Research and development. En *The AI Index 2026 annual report*. https://hai.stanford.edu/assets/files/ai_index_report_2026_chapter_1_research_development.pdf

Wang, Z., Ma, G., Du, P., y McIsaac, C. (2026, 3 de junio). *Using Muon optimizer with DeepSpeed*. PyTorch Blog. https://pytorch.org/blog/using-muon-optimizer-with-deepspeed/

Wen, K., Hall, D., Ma, T., y Liang, P. (2025). *Fantastic pretraining optimizers and where to find them* [Preprint]. arXiv. https://arxiv.org/abs/2509.02046