LECTURA DE TENDENCIA · SEMANA 1

Más allá de Adam: ¿mejor algoritmo o más cómputo?

Neural Networks: Deep Learning · Maestría en Ciencia de Datos y Máquinas de Aprendizaje · UIDE
Docente: Andrés Ordóñez-Bolaños

Cuando una red neuronal «aprende», lo que realmente hace es corregirse millones de veces. En cada corrección mide cuánto se equivocó y mueve un poquito sus pesos en la dirección que reduce el error. La pieza que decide cómo dar cada uno de esos pasos se llama **optimizador**, y durante casi diez años la respuesta casi universal fue la misma: Adam.

En 2025 y 2026 eso empezó a cambiar. Algunos de los laboratorios que entrenan los modelos más grandes del mundo comenzaron a usar optimizadores nuevos, con promesas de entrenar el doble de rápido. Al mismo tiempo, grupos independientes revisaron esas promesas con más cuidado y encontraron ventajas mucho más pequeñas. Esta lectura cuenta esa historia y, de paso, usa una pregunta muy concreta para pensar el deep learning de hoy: **si el cómputo es caro y escaso, ¿dónde conviene poner el esfuerzo: en mejores algoritmos, en más máquinas o en mejores datos?**

Aprender es bajar una montaña con neblina

La imagen más útil para entender el entrenamiento de una red es la de una persona que baja una montaña con neblina. No ve el valle; solo siente con los pies si el suelo baja hacia un lado o hacia el otro. Esa inclinación es el **gradiente**, y bajar paso a paso en contra de la inclinación es el **descenso de gradiente**. La altura en la que está la persona representa la **pérdida**: qué tan mal está prediciendo el modelo.

Con esa imagen, el optimizador es la forma de caminar:

- El **descenso de gradiente simple (SGD)** da siempre pasos del mismo tamaño en la dirección de la pendiente. Funciona, pero se desespera en las zonas planas y zigzaguea en los valles angostos.
- El **momentum** agrega inercia, como una bola que rueda: si varios pasos seguidos van en la misma dirección, acelera; si la pendiente cambia de un lado a otro, el zigzag se amortigua.
- **Adam** (Kingma y Ba, 2015) combina la inercia con algo más: lleva la cuenta de qué tan bruscas han sido las pendientes de cada parámetro y ajusta el tamaño del paso de cada uno por separado. Donde el terreno es muy irregular, camina con cuidado; donde es suave, se atreve más.

Una variante llamada **AdamW** corrigió la forma en que Adam aplicaba la regularización (Loshchilov y Hutter, 2019) y se convirtió en el estándar para entrenar modelos grandes. Si hoy usas Keras, PyTorch o un modelo de lenguaje abierto, es muy probable que detrás haya un AdamW.

> **Para entenderlo mejor.** Imagina que afinas una guitarra de seis cuerdas. SGD gira todas las clavijas lo mismo. Adam gira cada clavija según lo desafinada que ha estado esa cuerda en particular. Es más inteligente, pero sigue tratando cada cuerda como si no tuviera relación con las demás.

Por qué Adam reinó tanto tiempo

Adam ganó por una razón práctica: **funciona razonablemente bien casi siempre, sin mucho ajuste**. Para un equipo que entrena un modelo nuevo, eso vale oro, porque cada prueba fallida cuesta horas de GPU.

Pero Adam tiene dos rasgos que se vuelven importantes a gran escala. Primero, **mira cada número por separado**: un modelo de lenguaje tiene matrices de pesos enormes, y Adam las trata como una lista larga de números sueltos, sin aprovechar que forman una estructura. Segundo, **consume memoria**: para cada parámetro guarda dos valores adicionales (la inercia y la cuenta de qué tan bruscas fueron las pendientes). En un modelo con miles de millones de parámetros eso significa muchos gigabytes extra en cada GPU.

La tendencia: optimizadores que piensan en matrices

La novedad de los últimos dos años es una familia de optimizadores que tratan cada matriz de pesos **como un todo**. El más conocido es **Muon**, que nació como un experimento de la comunidad (Jordan, s. f.). Muon es, en esencia, el mismo descenso de gradiente con momentum que vemos en la Clase 1, con un paso adicional: antes de mover una matriz, «equilibra» la actualización para que empuje con la misma fuerza en todas sus direcciones, en vez de concentrarse en unas pocas. Las partes del modelo que no son matrices grandes se siguen entrenando con AdamW.

> **Para entenderlo mejor.** Piensa en enderezar un cuadro torcido en la pared. Adam empuja cada esquina por separado según cuánto se ha movido; Muon toma el marco completo y lo gira de forma pareja para que no se deforme.

Lo sorprendente fue la velocidad con la que la idea escaló:

Cuándo	Qué pasó
2024	Muon bate récords de velocidad en competencias abiertas para entrenar modelos pequeños tipo GPT-2 (Jordan, s. f.)
febrero de 2025	El laboratorio chino Moonshot AI reporta que, bien configurado, Muon necesita cerca de la mitad del cómputo que AdamW para el mismo resultado (Liu et al., 2025)
julio de 2025	Moonshot entrena Kimi K2, un modelo de un billón de parámetros, con una variante de Muon y sin los «picos» de pérdida que suelen arruinar entrenamientos largos (Kimi Team, 2025)
agosto de 2025	Zhipu AI y la Universidad Tsinghua usan Muon en GLM-4.5 y reportan que converge más rápido y tolera lotes más grandes (GLM-4.5 Team, 2025)
junio de 2026	PyTorch y DeepSpeed incorporan Muon; miden un ahorro de memoria por GPU cercano al 9 %, que ellos mismos llaman «modesto» (Wang et al., 2026)

Nota: en español, un billón es un millón de millones (10^{12}); en inglés se dice trillion.

En el caso de Kimi K2 hay una lección que va más allá de la velocidad: con un modelo de ese tamaño, un solo pico de pérdida puede desperdiciar semanas de cómputo. **La estabilidad del descenso de gradiente importa tanto como su rapidez.**

El contrapeso: la importancia de una carrera justa

Cuando aparece una mejora del doble, la pregunta científica correcta no es «¿cuánto ganó?», sino **«¿frente a qué rival y en qué condiciones?»**. Imagina una carrera en la que un corredor estrena zapatillas nuevas mientras su rival corre con las de siempre, mal amarradas. Ganar así no prueba que las zapatillas sean mejores. En deep learning ocurre algo parecido: muchos artículos comparan su método nuevo, ajustado con mucho cuidado, contra un AdamW configurado de forma rápida.

Tres estudios de 2025 intentaron poner a todos en la misma pista:

- **Wen, Hall, Ma y Liang (2025)**, de la Universidad de Stanford, compararon diez optimizadores dándole a cada uno el mismo cuidado de ajuste y probándolos en modelos de distintos tamaños. Encontraron que las ventajas reales son «menores que las reportadas»: los optimizadores matriciales como Muon ganan alrededor de 1.4 veces en modelos pequeños, pero esa ventaja se reduce a cerca de 1.1 veces en los modelos más grandes que probaron.
- **Semenov, Pagliardini y Jaggi (2025)**, de la EPFL en Suiza, señalaron que cada artículo usa un protocolo distinto, lo que hace casi imposible comparar. También notaron que un optimizador que gana en entrenamientos cortos puede perder ventaja cuando el entrenamiento es largo.
- **AlgoPerf** (Kasimbeg et al., 2025) organizó una competencia con reglas idénticas para todos y midió algo muy concreto: el tiempo real de reloj hasta alcanzar una meta. Ganó otro método que también aprovecha la estructura de las matrices (Distributed Shampoo), y en la categoría sin ajuste manual ganó una variante de AdamW.

La conclusión no es que los optimizadores nuevos sean un engaño. Es más matizada: **la mejora existe, pero buena parte de lo que parecía un salto enorme era un rival mal preparado**. Esta es una de las ideas más importantes de todo el curso: un resultado solo vale tanto como la comparación que lo respalda.

Mientras tanto, la escala manda

Para dimensionar el debate hay que mirar el tamaño de la cancha. El *AI Index 2026* de la Universidad de Stanford reporta que la capacidad mundial de cómputo dedicada a la IA crece más de tres veces por año desde 2022, que los centros de datos de IA ya consumen una potencia comparable a la de un estado grande de Estados Unidos, y que entrenar un solo modelo de frontera puede emitir decenas de miles de toneladas de CO_2 (Stanford HAI, 2026). La organización Epoch AI estimó que el cómputo usado para entrenar los modelos más notables creció entre cuatro y cinco veces por año entre 2010 y 2024 (Sevilla y Roldán, 2024).

Frente a un crecimiento así, un optimizador que ahorra entre 10 % y 50 % del cómputo es valioso, pero **no cambia el orden de magnitud** del problema.

El mismo informe deja dos señales que conviene tener presentes. La primera es preocupante: los laboratorios que entrenan los modelos más costosos ya no publican cuánto cómputo usaron, con qué datos ni durante cuánto tiempo, de modo que su costo real no se puede verificar. La segunda es alentadora: algunos modelos abiertos mucho más pequeños logran resultados comparables gracias a un trabajo cuidadoso con los datos, eliminando duplicados y seleccionando mejor qué aprender (Stanford HAI, 2026).

> **Para entenderlo mejor.** Un buen optimizador es como un mejor motor; los datos son el combustible. Un motor 20 % más eficiente ayuda, pero si el combustible está sucio, el auto igual falla.

Una mirada desde América Latina: Latam-GPT

¿Qué significa todo esto para una región con menos cómputo? El 10 de febrero de 2026 se presentó **Latam-GPT**, un modelo de lenguaje de 70 mil millones de parámetros liderado por el Centro Nacional de Inteligencia Artificial de Chile (CENIA), con alianzas en quince países (DPL News, 2026). Ecuador participó a través de varios actores, entre ellos el laboratorio «Alan Turing» de la Escuela Politécnica Nacional (Benalcázar, 2026).

La decisión técnica más interesante de Latam-GPT es que **no se entrenó desde cero**: partió de un modelo abierto existente, Llama 3.1, y concentró el esfuerzo en reunir y preparar datos de la región. Es, en la práctica, una respuesta a la pregunta de esta lectura: con un presupuesto acotado, se reutiliza el cómputo que ya invirtió otro y se invierte en lo que nadie más tiene, los datos propios. Un análisis de *Tech Policy Press* sostiene que su valor realista no está en competir con las grandes plataformas, sino en construir capacidades regionales y atender necesidades específicas, como las lenguas indígenas (Rivero, 2026).

Debates abiertos

Esta tendencia deja preguntas que no tienen una sola respuesta correcta y que vale la pena pensar con calma:

- **Promesa o medición.** ¿Una mejora del doble en un modelo de un billón de parámetros justifica cambiar de optimizador, aunque las comparaciones justas muestren ganancias menores en modelos medianos?
- **Algoritmos, máquinas o datos.** Si el cómputo crece varias veces por año y la curaduría de datos permite modelos pequeños muy capaces, ¿dónde rinde más cada dólar?
- **Transparencia.** ¿Deberían los laboratorios publicar cuánto cómputo y energía usan, dado su impacto ambiental?
- **Soberanía y responsabilidad.** ¿Necesita la región modelos propios, o es más responsable adaptar modelos existentes y cuidar los datos?

Para cerrar

La historia de Muon y Adam enseña algo que sirve mucho más allá de los optimizadores: en deep learning, las ideas nuevas se prueban en carreras justas, no en anuncios. Un científico de datos no defiende una técnica con adjetivos, sino con una comparación honesta, una métrica clara y el costo de obtenerla. Y en contextos como el nuestro, donde el cómputo es caro, la pregunta «¿qué mejora más mi modelo por cada hora de GPU?» suele tener una respuesta poco glamorosa pero poderosa: **mejores datos**.

Para profundizar

- *AI Index 2026*, capítulo 1 (Stanford HAI): gráficos accesibles sobre cómputo, costos y emisiones.
- Wen et al. (2025): basta leer el resumen y mirar la figura principal para entender qué es una comparación justa.
- Repositorio de Muon (Jordan, s. f.): explica el algoritmo en pocas líneas y con código.

Referencias

Benalcázar, M. E. (2026, 21 de febrero). Latam-GPT es el equivalente latinoamericano a ChatGPT. *El Comercio*. https://www.elcomercio.com/opinion/latam-gpt-equivalente-latinoamericano-chatgpt-marco-benelcazar-columnista/

DPL News. (2026, 10 de febrero). *Lanzan Latam-GPT, el primer modelo de lenguaje de IA colaborativo para América Latina*. https://dplnews.com/latam-gpt-modelo-de-lenguaje-de-ia-america-latina/

GLM-4.5 Team. (2025). *GLM-4.5: Agentic, reasoning, and coding (ARC) foundation models* [Preprint]. arXiv. https://arxiv.org/abs/2508.06471

Jordan, K. (s. f.). *Muon: An optimizer for the hidden layers of neural networks* [Repositorio de GitHub]. https://github.com/KellerJordan/Muon

Kasimbeg, P., Schneider, F., Eschenhagen, R., Bae, J., Sastry, C. S., Saroufim, M., Feng, B., Wright, L., Yang, E. Z., Nado, Z., Medapati, S., Hennig, P., Rabbat, M., y Dahl, G. E. (2025). Accelerating neural network training: An analysis of the AlgoPerf competition. En *International Conference on Learning Representations (ICLR 2025)*. https://arxiv.org/abs/2502.15015

Kimi Team. (2025). *Kimi K2: Open agentic intelligence* [Preprint]. arXiv. https://arxiv.org/abs/2507.20534

Kingma, D. P., y Ba, J. (2015). Adam: A method for stochastic optimization. En *International Conference on Learning Representations (ICLR 2015)*. https://arxiv.org/abs/1412.6980

Liu, J., Su, J., Yao, X., Jiang, Z., Lai, G., Du, Y., Qin, Y., Xu, W., Lu, E., Yan, J., y otros. (2025). *Muon is scalable for LLM training* [Preprint]. arXiv. https://arxiv.org/abs/2502.16982

Loshchilov, I., y Hutter, F. (2019). Decoupled weight decay regularization. En *International Conference on Learning Representations (ICLR 2019)*. https://arxiv.org/abs/1711.05101

Rivero, E. (2026, 2 de marzo). LatamGPT navigates the gap between regional aspiration and market realities. *Tech Policy Press*. https://www.techpolicy.press/latamgpt-navigates-the-gap-between-regional-aspiration-and-market-realities

Semenov, A., Pagliardini, M., y Jaggi, M. (2025). *Benchmarking optimizers for large language model pretraining* [Preprint]. arXiv. https://arxiv.org/abs/2509.01440

Sevilla, J., y Roldán, E. (2024, 28 de mayo). *Training compute of frontier AI models grows by 4-5x per year*. Epoch AI. https://epoch.ai/blog/training-compute-of-frontier-ai-models-grows-by-4-5x-per-year

Stanford Institute for Human-Centered Artificial Intelligence. (2026). Research and development. En *The AI Index 2026 annual report*. https://hai.stanford.edu/assets/files/ai_index_report_2026_chapter_1_research_development.pdf

Wang, Z., Ma, G., Du, P., y McIsaac, C. (2026, 3 de junio). *Using Muon optimizer with DeepSpeed*. PyTorch Blog. https://pytorch.org/blog/using-muon-optimizer-with-deepspeed/

Wen, K., Hall, D., Ma, T., y Liang, P. (2025). *Fantastic pretraining optimizers and where to find them* [Preprint]. arXiv. https://arxiv.org/abs/2509.02046