LECTURA DE TENDENCIA · SEMANA 2

¿El regreso de las redes recurrentes? Transformers, Mamba y la búsqueda de la arquitectura ideal

Neural Networks: Deep Learning · Maestría en Ciencia de Datos y Máquinas de Aprendizaje · UIDE
Docente: Andrés Ordóñez-Bolaños

Si hoy le preguntas a un chatbot cualquier cosa, la respuesta la produce casi con seguridad un **Transformer**, la arquitectura que desde 2017 domina el procesamiento de lenguaje y que también se extendió a imágenes, audio y video. Durante años pareció que la discusión sobre arquitecturas estaba cerrada: las redes recurrentes, que leían el texto palabra por palabra, habían quedado como un capítulo de la historia.

Pero algo inesperado está ocurriendo. Desde 2024, varios de los modelos abiertos más avanzados del mundo volvieron a incorporar **capas recurrentes**, en versiones modernas y eficientes. Esta lectura explica por qué, qué se gana y qué se pierde, y qué nos enseña sobre una pregunta que atraviesa todo el curso: **¿qué pesa más en un buen modelo, la arquitectura o el cómputo, los datos y la forma de evaluarlo?**

Cada arquitectura es una forma de mirar los datos

Una arquitectura no es solo una lista de capas: es una **suposición sobre cómo están organizados los datos**.

- Una **red densa** supone que cualquier entrada puede relacionarse con cualquier otra. Sirve para tablas, como los datos de una cooperativa.
- Una **red convolucional (CNN)** supone que lo cercano importa más que lo lejano: un borde, una esquina o una textura se reconocen mirando una pequeña ventana de la imagen, y el mismo filtro sirve en cualquier parte de ella. Por eso las CNN dominaron la visión por computador desde 2012.
- Una **red recurrente (RNN)** supone que el orden importa: lee una secuencia elemento por elemento y va guardando lo leído en un **estado oculto**.

> **Para entenderlo mejor.** Una CNN mira una foto con una lupa que recorre toda la imagen. Una RNN lee un libro con una libreta pequeña en la que va resumiendo lo que lleva leído.

La libreta de la RNN y sus límites

La libreta de la RNN tiene un tamaño fijo. Eso es una ventaja, porque el costo de leer cada palabra nueva es siempre el mismo. Pero tiene dos problemas que se ven en clase.

El primero es el **olvido**: al entrenar con secuencias largas, la señal de error que viaja hacia atrás se debilita en cada paso y la red no aprende relaciones lejanas. La **LSTM** (Hochreiter y Schmidhuber, 1997) mitigó el problema con «compuertas» que deciden qué guardar, qué olvidar y qué mostrar, y durante

dos décadas fue la reina de las secuencias: traducción, reconocimiento de voz, predicción de series de tiempo.

El segundo problema es más práctico: la RNN **no se puede paralelizar**. Para procesar la palabra cien necesita haber procesado las noventa y nueve anteriores. Las GPU, que son excelentes haciendo miles de operaciones al mismo tiempo, quedan subutilizadas.

La revolución de la atención

En 2017, un equipo de Google propuso abandonar la recurrencia por completo. Su artículo, *Attention is all you need* (Vaswani et al., 2017), presentó el Transformer. Su idea central, la **atención**, permite que cada palabra mire directamente a todas las demás y decida cuáles son relevantes para entenderla. En la frase «el socio pagó la cuota porque *él* recibió su sueldo», la atención ayuda a que «él» se conecte con «socio» y no con «cuota».

Esto trajo dos ventajas enormes. Primero, ya no hay libreta que se llene: el modelo puede consultar cualquier parte del texto con precisión. Segundo, todo se calcula **en paralelo**, lo que permitió entrenar con cantidades de datos antes impensables. De ahí salieron BERT, GPT y prácticamente todos los modelos de lenguaje actuales.

Pero la atención tiene un precio. Para generar cada palabra nueva, el modelo la compara con **todas** las anteriores, y además guarda en memoria una representación de cada una (la llamada *caché KV*). Cuanto más largo el texto, más memoria y más cálculo. El costo de la atención crece con el cuadrado de la longitud.

> **Para entenderlo mejor.** La RNN escribe una carta mirando solo su libreta de resumen. El Transformer, antes de escribir cada palabra, relee la carta completa desde el principio. Recuerda todo, pero cada palabra nueva le cuesta un poco más que la anterior.

Mientras los textos eran cortos, ese costo era tolerable. Hoy los modelos trabajan con contextos de cientos de miles o incluso un millón de palabras, y los «agentes» de IA pueden trabajar durante horas sobre la misma tarea. El costo de releerlo todo se convirtió en el cuello de botella.

La tendencia: las redes recurrentes vuelven, en versión moderna

La solución que exploraron los laboratorios entre 2023 y 2026 fue recuperar la idea de la libreta, pero con dos mejoras: que se pueda **entrenar en paralelo**, como un Transformer, y que la red decida mejor **qué anotar**. De ahí nacieron los *state space models*, como **Mamba** (Gu y Dao, 2023), cuya segunda versión mostró que estos modelos y la atención son, matemáticamente, primos cercanos (Dao y Gu, 2024). Incluso la LSTM tuvo su regreso: el grupo de Sepp Hochreiter, uno de sus creadores, presentó **xLSTM 7B**, un modelo de lenguaje recurrente que reporta generar texto más rápido que modelos de su tamaño basados en Transformers y en Mamba (Beck et al., 2025).

Sin embargo, la tendencia más fuerte no fue reemplazar al Transformer, sino **mezclarlo**: los modelos **híbridos** conservan unas pocas capas de atención completa, que funcionan como un buscador preciso dentro del texto, y usan capas recurrentes baratas en todo lo demás.

Cuándo	Modelo	Idea principal
2024	Jamba (AI21 Labs)	Una capa de atención por cada siete capas de Mamba (Lieber et al., 2024)
2025	Nemotron-H (NVIDIA)	Reemplaza cerca del 92 % de las capas de atención por Mamba-2 y reporta hasta 3 veces más velocidad al generar texto, con exactitud comparable (NVIDIA, 2025; AI21 Labs, 2025)
2025	Kimi Linear (Moonshot AI)	Usa hasta 75 % menos memoria de caché y genera hasta 6 veces más rápido con textos de un millón de tokens (Kimi Team, 2025)
2026	Qwen3.5 (Alibaba)	Tres capas de atención «lineal» por cada capa de atención completa, en un modelo de casi 400 mil millones de parámetros (Labonne, 2026)
2026	Nemotron 3 Super (NVIDIA)	Híbrido Mamba–atención que reporta hasta 2.2 veces más rendimiento que un Transformer abierto de tamaño parecido (NVIDIA, 2026)

Para entenderlo mejor. Un modelo híbrido funciona como un buen estudiante preparando un examen: toma apuntes resumidos de casi todo (capas recurrentes) y, de vez en cuando, vuelve al libro para buscar un dato exacto (capas de atención).

El contrapeso: lo que la libreta no puede guardar

Que algo sea más barato no significa que sea igual de bueno. Hay tres advertencias importantes.

La libreta tiene un límite. Jelassi, Brandfonbrener, Kakade y Malach (2024) demostraron que un Transformer pequeño puede copiar textos muy largos de forma exacta, mientras que un modelo con estado de tamaño fijo está limitado por lo que cabe en ese estado. En sus experimentos, los Transformers fueron claramente mejores para copiar y recuperar información precisa del contexto. Es intuitivo: si alguien te dicta un número de teléfono largo y solo puedes anotar un resumen, tarde o temprano pierdes dígitos.

Los benchmarks pueden engañar. El laboratorio MiniMax apostó en 2025 por la atención eficiente, pero para su modelo M2 decidió **volver a la atención completa**. En una publicación inusualmente honesta explicó que su modelo híbrido igualaba a la atención completa en las pruebas tradicionales, pero que a mayor escala mostró «claros déficits» en tareas de razonamiento complejo de varios pasos, y que verificar alternativas en tareas difíciles exige un cómputo que «crece astronómicamente» (MiniMax, 2025).

No hay consenso. A comienzos de 2026, entre los modelos abiertos más fuertes conviven Transformers clásicos, variantes de atención comprimida o dispersa y diversos híbridos. Como resumió un análisis de ese momento, «ya nadie se pone de acuerdo sobre la atención» (Labonne, 2026).

La misma lección, ahora en visión: CNN contra Transformers

Algo parecido ocurrió con las imágenes. Desde 2020, los *Vision Transformers* (ViT) se presentaron como los sucesores de las CNN, y muchos asumieron que las convoluciones habían quedado obsoletas. En 2023, investigadores de Google DeepMind hicieron una prueba sencilla: entrenaron CNN con **el mismo presupuesto de cómputo** que los ViT más fuertes. El resultado fue un empate técnico, con más de 90 % de exactitud en ImageNet. Su conclusión fue tajante: no hay evidencia fuerte de que los ViT superen

a las CNN «cuando se evalúan con justicia»; lo que más pesó fueron el cómputo y los datos (Smith et al., 2023).

Es la misma moraleja de la semana 1 con los optimizadores: **antes de declarar un ganador, hay que asegurarse de que todos corrieron la misma carrera**.

Una mirada desde América Latina: el costo de usar un modelo

En la región, el desafío más frecuente no es entrenar un modelo gigante, sino **usarlo todos los días**: en un hospital, en una cooperativa o en una entidad pública que tiene pocas GPU y muchos usuarios. Latam-GPT, por ejemplo, se construyó sobre un Transformer abierto ya existente, Llama 3.1, para no tener que entrenar desde cero (DPL News, 2026).

Por eso, la tendencia hacia arquitecturas más eficientes al generar texto puede tener efectos prácticos aquí. Si un modelo necesita mucha menos memoria para trabajar con textos largos, se abre la posibilidad de analizar documentos extensos en español, como expedientes, contratos o normativas, en hardware que una organización de la región sí puede pagar. Al mismo tiempo, la advertencia de MiniMax recuerda que esa eficiencia debe comprobarse en las tareas reales que nos importan, no solo en pruebas estándar.

Debates abiertos

- **Eficiencia o capacidad.** ¿Vale la pena ganar dos a seis veces en velocidad si se arriesga la capacidad de recordar con exactitud y razonar en varios pasos?
- **Arquitectura o escala.** Si con el mismo cómputo y los mismos datos las arquitecturas bien diseñadas rinden parecido, ¿cuánto debemos preocuparnos por elegir la arquitectura «perfecta»?
- **Benchmarks o uso real.** ¿Cómo evaluar un modelo para que las pruebas reflejen las tareas largas y complejas del mundo real?
- **Abierto o cerrado.** Los laboratorios abiertos publican sus arquitecturas, pero no sabemos qué usan los modelos cerrados más potentes. ¿Qué tan completo es entonces este debate?

Para cerrar

La historia de las arquitecturas no es una línea recta en la que cada idea nueva entierra a la anterior. Las CNN siguen vivas, la recurrencia volvió y el Transformer se mezcla con ambas. Cada arquitectura es una apuesta sobre qué estructura tienen los datos y qué recursos tenemos para procesarlos. Para un científico de datos, la habilidad más valiosa no es conocer la arquitectura de moda, sino saber **qué suposición hace cada una, qué cuesta y cómo comprobar, con una comparación justa, si es la adecuada para su problema**.

Para profundizar

- Raschka, S. (s. f.). *LLM architecture gallery: Hybrid attention*: diagramas que comparan visualmente los modelos híbridos.
- MiniMax (2025): una lectura corta y honesta sobre por qué una idea prometedora no llegó a producción.
- Smith et al. (2023): el resumen basta para entender por qué «comparar con justicia» cambia las conclusiones.

Referencias

AI21 Labs. (2025, 5 de agosto). *Attention was never enough: Tracing the rise of hybrid LLMs*. https://www.ai21.com/blog/rise-of-hybrid-llms/

Beck, M., Pöppel, K., Lippe, P., Kurle, R., Blies, P. M., Klambauer, G., Böck, S., y Hochreiter, S. (2025). xLSTM 7B: A recurrent LLM for fast and efficient inference. En *Proceedings of the 42nd International Conference on Machine Learning* (PMLR 267, pp. 3335–3357). https://proceedings.mlr.press/v267/beck25b.html

Dao, T., y Gu, A. (2024). Transformers are SSMs: Generalized models and efficient algorithms through structured state space duality. En *Proceedings of the 41st International Conference on Machine Learning* (PMLR 235). https://arxiv.org/abs/2405.21060

DPL News. (2026, 10 de febrero). *Lanzan Latam-GPT, el primer modelo de lenguaje de IA colaborativo para América Latina*. https://dplnews.com/latam-gpt-modelo-de-lenguaje-de-ia-america-latina/

Gu, A., y Dao, T. (2023). *Mamba: Linear-time sequence modeling with selective state spaces* [Preprint]. arXiv. https://arxiv.org/abs/2312.00752

Hochreiter, S., y Schmidhuber, J. (1997). Long short-term memory. *Neural Computation, 9*(8), 1735–1780. https://doi.org/10.1162/neco.1997.9.8.1735

Jelassi, S., Brandfonbrener, D., Kakade, S. M., y Malach, E. (2024). Repeat after me: Transformers are better than state space models at copying. En *Proceedings of the 41st International Conference on Machine Learning* (PMLR 235, pp. 21502–21521). https://proceedings.mlr.press/v235/jelassi24a.html

Kimi Team. (2025). *Kimi Linear: An expressive, efficient attention architecture* [Preprint]. arXiv. https://arxiv.org/abs/2510.26692

Labonne, M. (2026, 17 de febrero). *Qwen3.5: Nobody agrees on attention anymore*. Medium. https://medium.com/@mlabonne/qwen3-5-nobody-agrees-on-attention-anymore-4709e1bd014b

Lieber, O., Lenz, B., Bata, H., Cohen, G., Osin, J., y otros. (2024). *Jamba: A hybrid Transformer-Mamba language model* [Preprint]. arXiv. https://arxiv.org/abs/2403.19887

MiniMax. (2025, 30 de octubre). *Why did M2 end up as a full attention model?* Hugging Face Blog. https://huggingface.co/blog/MiniMax-AI/why-did-m2-end-up-as-a-full-attention-model

NVIDIA. (2025). *Nemotron-H: A family of accurate and efficient hybrid Mamba-Transformer models* [Preprint]. arXiv. https://arxiv.org/abs/2504.03624

NVIDIA. (2026). *Nemotron 3 Super: Open, efficient mixture-of-experts hybrid Mamba-Transformer model for agentic reasoning* [Preprint]. arXiv. https://arxiv.org/abs/2604.12374

Raschka, S. (s. f.). *LLM architecture gallery: Hybrid attention*. https://sebastianraschka.com/llm-architecture-gallery/hybrid-attention/

Smith, S. L., Brock, A., Berrada, L., y De, S. (2023). *ConvNets match vision transformers at scale* [Preprint]. arXiv. https://arxiv.org/abs/2310.16764

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., y Polosukhin, I. (2017). Attention is all you need. En *Advances in Neural Information Processing Systems 30* (pp. 5998–6008). https://arxiv.org/abs/1706.03762