Acertar no basta

Neural Networks: Deep Learning · Robustez, transfer learning y explicabilidad

UIDE · Maestría en Ciencia de Datos

Semana 3

Andrés Ordóñez-Bolaños, MSc

Semana 3 · noviembre de 2026 · Microsoft Teams



La foto original · la red dice botín

botín	96 %
zapatilla	2 %
sandalia	1 %
bolso	0 %

La semana en dos temas

Dos preguntas: **¿funcionará con casos nuevos?** y **¿puedo reutilizar lo que otra red aprendió y explicar lo que decide?** Antes, un recorderis; al final, el cierre.

00

Recorderis

Las semanas 1 y 2 en una sola cadena, y tres preguntas para calentar.

Sin notebook

≈ 15 min

→

TEMA 1

¿Funcionará con casos nuevos?

Memorizar contra aprender, frenos para la memoria, la foto movida, el ruido invisible y afinar sin trampa.

NB05 en clase

≈ 1 h 45

→

TEMA 2

Reutilizar y explicar

Transfer learning, dónde miró la red, la prueba de cordura y cómo explicarle un «no» a una socia.

NB06 en clase

≈ 2 h

→

CIERRE

¿Le creerías a tu red?

Cinco preguntas antes de usar un modelo con personas, tu proyecto y el quiz final.

Quiz final

≈ 40 min

Cada sesión **sigue donde terminó la anterior**: el orden importa, el reloj no. Las prácticas son en clase y **no tienen nota**.

Antes de empezar: ¿de dónde partimos?

8 preguntas cortas tipo Kahoot. **No es nota**: es tu punto de partida para medir cuánto avanzas esta semana.

1. Escanea el código o abre **deeplearningweek1.vercel.app/?pre3**
2. Escribe tu nombre (el mismo de las semanas 1 y 2) y responde rápido: **más rapidez, más puntos**
3. Al final, copia tu código y **pégalo en el chat de Teams**

✓ Si no sabes una, elige la que te parezca. Equivocarse aquí es parte del plan.

deeplearningweek1.vercel.app/?pre3

Al terminar la semana vas a poder explicar estas 5 ideas

Las medimos dos veces: en este pre-quiz y en el quiz final del cierre.

1. Aprender no es memorizar
2. Regularizar es ponerle frenos a la memoria
3. Exacto no es robusto
4. Transfer learning: reutilizar lo que otra red ya aprendió
5. Explicar y verificar: una explicación también tiene que pasar pruebas

Tema 1: **ideas 1, 2 y 3**. Tema 2: **ideas 4 y 5**. Cada una tiene su lámina con la etiqueta amarilla **Idea clave**.

00

Recorderis: semanas 1 y 2

Antes de preguntarnos si la red es confiable, repasemos en 15 minutos cómo aprende, qué arquitecturas vimos y qué resultados obtuvimos.

- Las dos semanas en una cadena
- Tres preguntas

≈ 15 minutos

Las semanas 1 y 2 en una sola cadena

Nueve eslabones: cómo aprende una red y cómo se elige su forma.

1 Neurona

`z = w·x + b`

como la nota final: cada dato por lo que pesa · socio A: `z = 2.81`

2 Pérdida y gradiente

`peso - η · pendiente`

bajar el Cotopaxi con neblina, un paso a la vez; **η** es el largo del paso

3 Retropropagación

`repartir la culpa hacia atrás`

los engranajes: la regla de la cadena, capa por capa

4 Keras

`Sequential · compile · fit`

TensorFlow es el motor; Keras, el volante

5 Simulacro y examen

`estudiar · validar · probar`

estudia unas fotos, se mide en un **simulacro** y al final en el **examen**

6 La suposición

`densa · CNN · RNN · atención`

cada arquitectura es una apuesta sobre cómo están organizados los datos

7 La lupa de la CNN

`filtros compartidos`

la CNN acierta el `87.7 %` con 8 veces menos números

8 Mover la prenda

`2 píxeles a la derecha`

densa `56.5 %`, CNN `75.2 %`; con 4 píxeles, las dos se caen

9 La atención

`buscar el dato exacto`

con 80 pasos las recurrentes adivinan; la atención acierta el `100 %`

Ya sabemos construir redes que **aciertan**. Esta semana: ¿funcionan con **casos nuevos**? ¿Las podemos **reutilizar** y **explicar**?

Tres preguntas para calentar

Respondan en el chat **antes** de que aparezca la respuesta. Vienen de las semanas 1 y 2.

1 En `fit(…, validation_split=0.2)`, ¿qué es ese 20 %?

El **simulacro**: fotos que la red no estudia.

Sirve para ver si aprende o memoriza, y para decidir sin tocar el examen final. Lo usamos en todo el Tema 1.

2 ¿Por qué la CNN necesita unas **8 veces menos** parámetros que la densa?

Comparte sus filtros. El mismo filtro de 9 pesos recorre toda la foto.

12 810 contra 101 770 números, y aun así acierta más.

3 La CNN acierta el 87.7 %. Si movemos cada foto **4 píxeles**, ¿cuánto acierta?

28.2 %. Se cae.

Exacta no significa robusta: es el punto de partida del Tema 1.



¿Funcionará con casos nuevos?

Una red que acierta lo que ya vio no garantiza nada. Hay que probarla con lo que no vio y con lo que cambia.

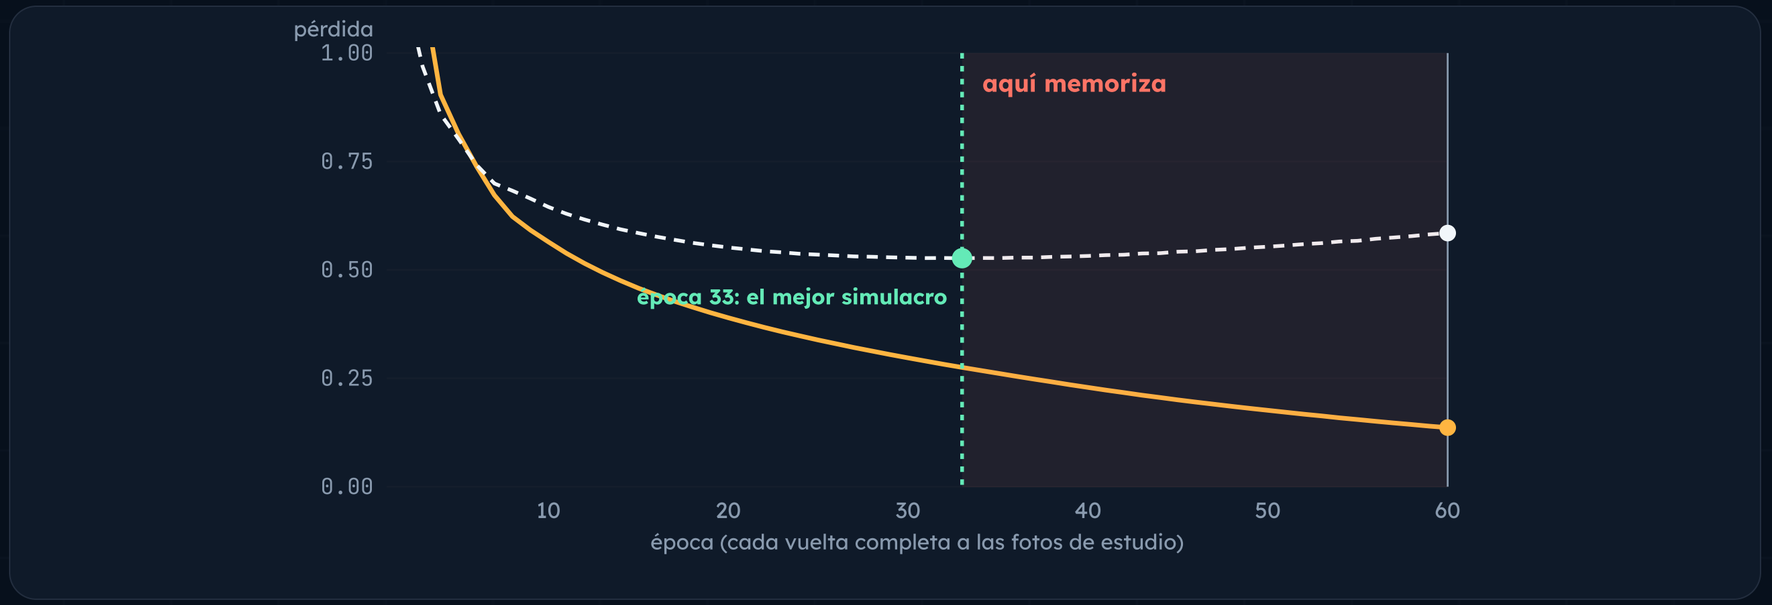
Memorizar · Por qué memoriza · Frenos · Aumento · Con frenos · En Keras · Mover la foto · Ruido invisible · La receta · Vacunar · El mundo cambia · Afinar · Práctica NB05

Tema 1 · ≈ 1 h 45 con el NB05

Aprender no es memorizar

Idea clave 1

La CNN de la semana 2 estudia solo **1 000 fotos**, 60 épocas. Como quien memoriza el solucionario: **96.7 %** en lo que estudió y **83.0 %** en el simulacro.



época 60

- Entrenamiento · 1 000 fotos
- Simulacro · 2 000 fotos

ENTRENAMIENTO
96.7 %
pérdida 0.14

SIMULACRO
83.0 %
pérdida 0.58

El sobreajuste: la pérdida de entrenamiento **sigue bajando** y la del simulacro **sube**. Examen final: 80.9 %.

¿Por qué memoriza una red? Idea clave 1

Memorizar no es un error de programación: es lo que pasa cuando la red puede guardarse los detalles de sus ejemplos.

Entrenamiento

las fotos que estudia · aquí 1 000

el cuaderno de ejercicios

Validación

el simulacro · 2 000 fotos que no estudia

decide cuándo parar y qué ajustar

Prueba

el examen final · 10 000 fotos

se mira una sola vez, al final

Muchos números, pocos ejemplos

La CNN tiene **12 810** números que aprender y solo ve **1 000** fotos: unos 13 números por foto. Le alcanza para guardarse detalles.

Estudiar de más

En 60 épocas ve **cada foto 60 veces**. Llega un momento en que ya no aprende nada general: repasa lo mismo.

Detalles que no se repiten

Una arruga, una sombra o un fondo raro existen solo en **esas** fotos. Si los aprende, no le sirven para fotos nuevas.

El mejor remedio es tener más datos. La misma red con las 60 000 fotos llega a `87.7 %` en el examen; con 1 000, a `80.9 %`.

Regularizar es ponerle frenos a la memoria

Idea clave 2

Tres frenos que se usan casi siempre: hacen que memorizar sea más difícil que aprender.



lote 1 · descansan 3 de 12

Dropout

Un equipo en el que, en cada partido, **puede faltar cualquiera**: nadie depende de un solo compañero.

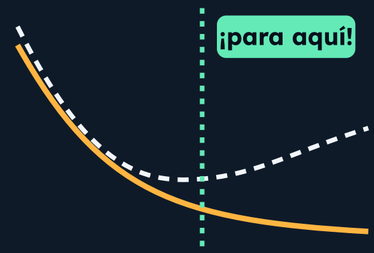
en cada lote descansa al azar una parte de las neuronas



Aumento de datos

Practicar con la prenda movida: así no te sorprende verla corrida.

en cada época, versiones un poco movidas de las mismas fotos



Parar a tiempo

Dejar de estudiar cuando el simulacro empieza a salir peor.

early stopping: vigila el simulacro y se queda con la mejor época

De pasada: **L2** castiga los pesos grandes. Y el freno más fuerte sigue siendo **tener más datos**.

Aumento: la misma prenda, movida

Idea clave 2

No son fotos nuevas: son **versiones distintas** de las mismas, otras en cada época.
Un botín movido sigue siendo un botín.



La foto original · siempre la misma respuesta



Lo que estudia la red en la época 1 · 10 versiones movidas



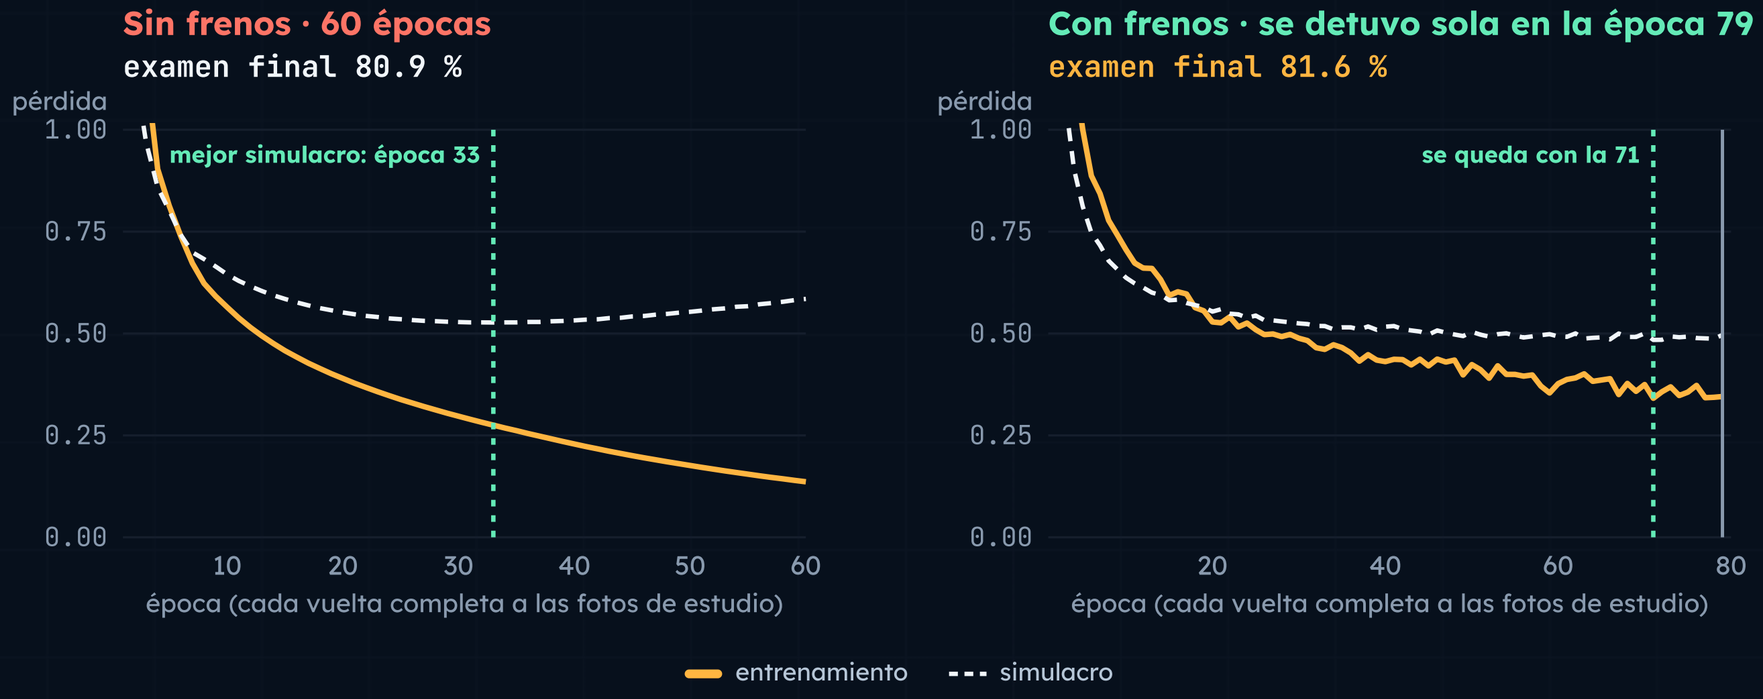
`RandomTranslation(0.15)` : cada copia se mueve al azar hasta 4 píxeles (15 % de 28) y el borde se rellena como un espejo. Sigue siendo un **botín**.

Solo cambios que no cambien la respuesta: mover un poco la prenda, sí; ponerla de cabeza, no.

Con frenos: lo que pasó

Idea clave 2

Las mismas 1 000 fotos con **aumento**, **dropout** y **parar a tiempo**, y hasta 100 épocas.



Las curvas ya no se separan. Los frenos ayudan **un poco** (`80.9 %` → `81.6 %`); **más datos ayudan mucho**: con las 60 000 fotos, `87.7 %`.

Los frenos en Keras: tres líneas

La CNN de la semana 2, con dos capas nuevas y un *callback*.

```
model = keras.Sequential([
    keras.Input(shape=(28, 28, 1)),
    layers.RandomTranslation(0.05, 0.05),  # shifts
    layers.Conv2D(16, 3, activation="relu"),
    layers.MaxPooling2D(2),
    layers.Conv2D(32, 3, activation="relu"),
    layers.MaxPooling2D(2),
    layers.Flatten(),
    layers.Dropout(0.3),                   # rests
    layers.Dense(10, activation="softmax"),
])
stop = keras.callbacks.EarlyStopping(monitor="val_loss",
    patience=8, restore_best_weights=True)
model.fit(x_small, y_small, epochs=100, callbacks=[stop],
          validation_data=(x_val, y_val))
```

`RandomTranslation(0.05, 0.05)`

mueve cada foto hasta un 5 % (≈ 1 píxel). Solo al entrenar.

`Dropout(0.3)`

en cada lote apaga al azar el 30 % de los 800 números antes de la salida. Al predecir, juegan todos.

`EarlyStopping(patience=8, …)`

un *callback*: si el simulacro no mejora en 8 épocas, para y vuelve a la mejor.

Para en la **79**, se queda con la **71**: **81.6 %** en el examen.

Mover la foto: con aumento, aguanta

Idea clave 3

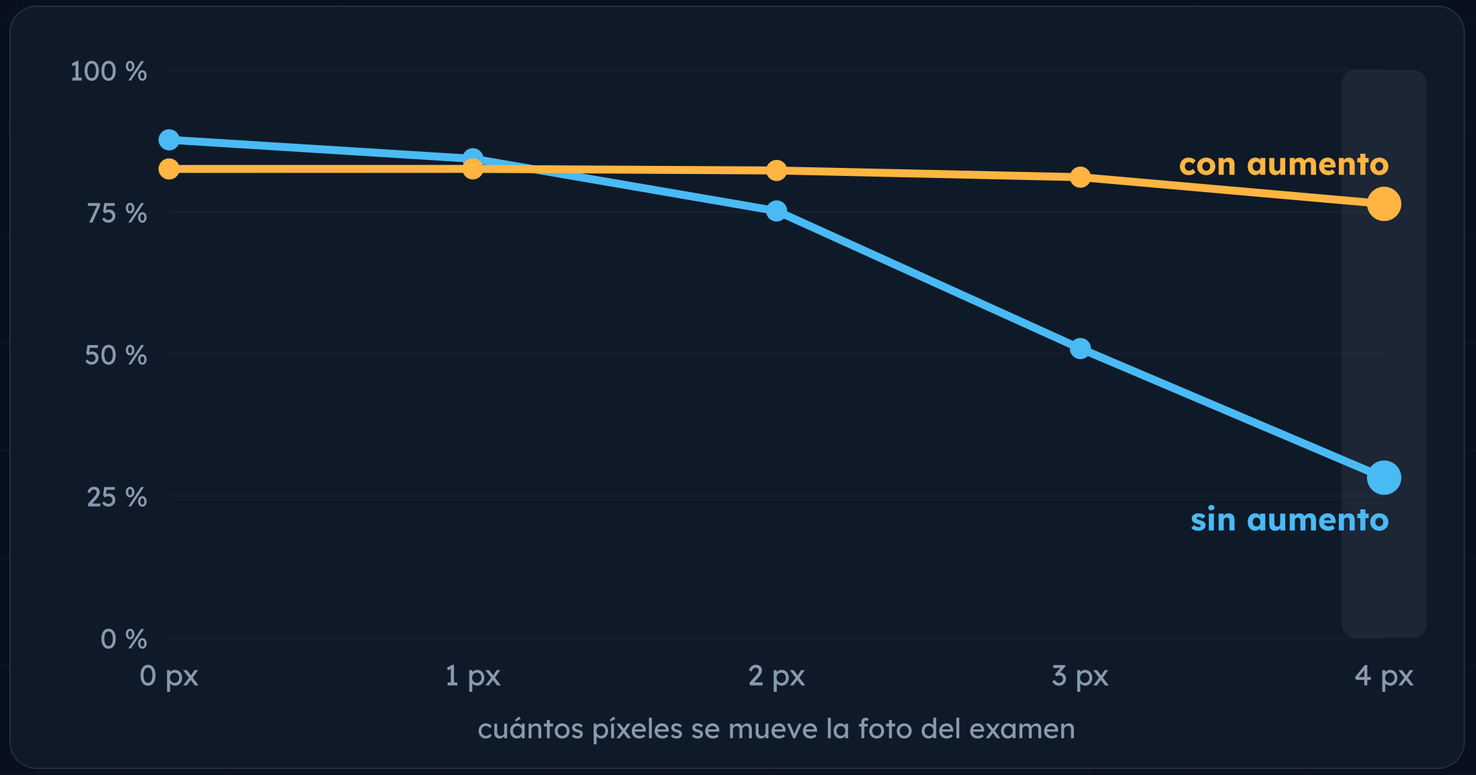
60 000 fotos y 5 épocas, como en la semana 2. Después movemos las fotos del examen de 1 a 4 píxeles.



El botín, movido 4 píxeles a la derecha

mover 4 px

SIN AUMENTO	CON AUMENTO
28.2 %	76.4 %



Con 4 píxeles: 28.2 % → 76.4 %. El precio: sin mover, de 87.7 % a 82.6 %.

Exacto no es robusto: el ruido invisible

Idea clave 3

La CNN acierta el **87.7 %**. Le sumamos a una foto un ruido invisible, calculado para engañarla.



La foto · botín del examen

La red dice

botín	96 %
zapatilla	2 %
sandalia	1 %
bolso	0 %

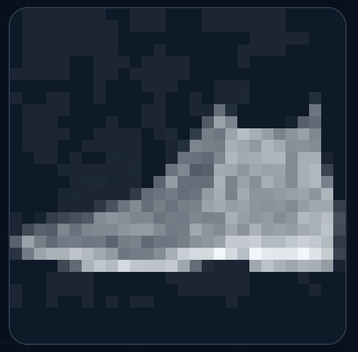
+



Ruido · aumentado para que se vea

Ámbar: el píxel sube; azul: baja. Cada píxel cambia **como máximo 13 de 255** (ε = 0.05).

=



La foto engañosa

La red dice

botín	20 %
zapatilla	67 %
sandalia	8 %
bolso	5 %

Para nosotros es la misma foto; para la red, una **zapatilla**. Es un **ejemplo adversarial** (Goodfellow et al., 2015).

La receta: subir la montaña a propósito

Idea clave 3

En la semana 1 los **pesos** bajaban para que la pérdida baje. Aquí cada **píxel** sube un poquito para que la pérdida suba.

$$x' = x + \varepsilon \cdot \text{signo}(\nabla_x \text{pérdida})$$

- x' — la foto engañosa
- x — la foto
- ε — cuánto se mueve cada píxel
- $\text{signo}(\nabla_x \text{pérdida})$ — ¿sube o baja la pérdida con cada píxel?

Léelo así: la pendiente de la pérdida respecto a cada píxel dice hacia dónde «duele» más. Se toma solo su signo (+1 o −1) y se da **un paso de tamaño ε** en esa dirección.

```
x = tf.convert_to_tensor(photos)
with tf.GradientTape() as tape:
    tape.watch(x)                    # slope per pixel
    loss = loss_fn(labels, model(x))
grad = tape.gradient(loss, x)
x_adv = x + eps * tf.sign(grad)    # one step uphill
x_adv = tf.clip_by_value(x_adv, 0, 1)   # valid photo
```

Entrenar · semana 1

`peso - η · pendiente`

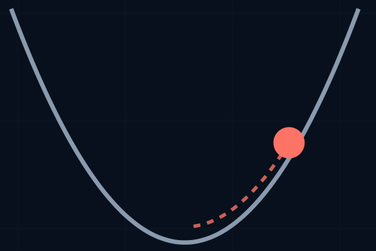


pérdida

los pesos bajan: la pérdida se achica

Atacar · esta semana

`píxel + ε · signo(pendiente)`



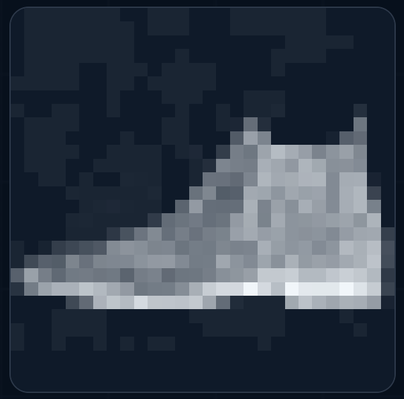
pérdida

el píxel sube: la pérdida crece

¿Cuánto ruido aguanta? Y la vacuna

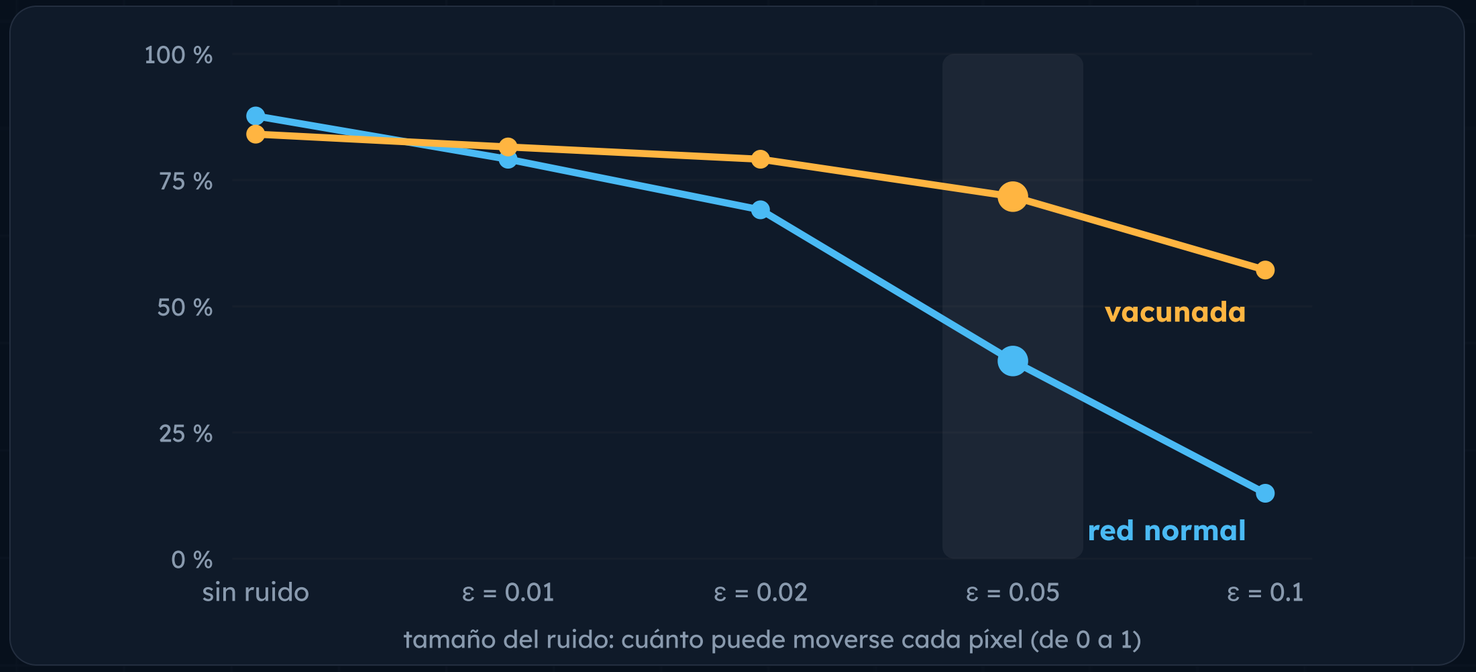
Idea clave 3

Entrenamiento adversarial: cada lote trae las fotos limpias **y su versión engañosa**. Es vacunarse.



ε = 0.05 · cada píxel cambia hasta 13 de 255

RED NORMAL	VACUNADA
39.2 %	71.7 %



sin ruido | ε 0.01 | ε 0.02 | ε 0.05 | ε 0.1

Con ε = 0.05: 39.2 % → 71.7 %. La vacuna tiene un costo: con fotos limpias baja de 87.7 % a 84.1 %.

El mundo cambia y el modelo no avisa

Idea clave 3

Tres cambios pequeños que tumban a un modelo exacto. El tercero es el más común y el más silencioso.

Mover la foto

87.7 % → 28.2 %

Cuatro píxeles a la derecha. La cámara se corrió un poco.

NB05 · sección 3

Ruido invisible

87.7 % → 39.2 %

Un cambio de 13 de 255 en cada píxel, hecho a propósito para engañarla.

NB05 · sección 4

El mundo cambia

urbanos → rurales

Un modelo de crédito entrenado con socios urbanos se usa con socios rurales, o antes y después de una crisis.

Lectura de tendencia

Lectura de tendencia

«El modelo no avisa: sigue respondiendo con la misma seguridad». Una explicación de un modelo que no generaliza puede ser **una explicación muy clara de un error**.

Por eso: probar con datos **parecidos a donde se va a usar**, y seguir midiendo después de ponerlo a trabajar.

Afinar sin hacer trampa: búsqueda al azar

Parámetros: lo que la red aprende. **Hiperparámetros**: lo que tú eliges antes. Probamos 6 combinaciones al azar y elegimos con el **simulacro**.

#	LEARNING RATE	FILTROS	DROPOUT	PARÁMETROS	SIMULACRO
1	0.01	8 y 16	0	5 258	85.2 %
2	0.001	16 y 32	0	12 810	81.0 %
3	0.0001	16 y 32	0.3	12 810	69.3 %
4	0.001	32 y 64	0.3	34 826	82.2 %
5	0.01	32 y 64	0.3	34 826	86.8 %
6	0.0001	32 y 64	0.3	34 826	72.6 %

La mejor combinación, en el **examen final** y una sola vez: **86.9 %**

Afinar la guitarra con el simulacro

Se afina tocando en el ensayo, nunca en el concierto. Si afinas mirando el examen final, el examen deja de medir casos nuevos.

Tocar el examen **una sola vez**, al final, es lo que hace creíble el número.

Práctica en clase: NB05

En clase · sin nota

35 minutos

En parejas. Todo el código ya viene escrito y comentado. Antes de cada celda, apuesta qué va a salir.

Qué deberías ver

- **1** · El estudiante que memoriza: **96.7 %** estudiando, **83.0 %** en el simulacro; el mejor en la época **33**
- **2** · Con frenos: para en la **79**, se queda con la **71**, examen **81.6 %**
- **3** · Mover 4 píxeles: sin aumento **28.2 %**, con aumento **76.4 %**
- **4** · El botín engañado: **zapatilla 67 %**; con ε = 0.05 la red acierta **39.2 %**
- **5** · La red vacunada: **71.7 %** con ε = 0.05
- **6** · La mejor combinación: **86.8 %** en el simulacro, **86.9 %** en el examen

deeplearningweek1.vercel.app/?nb05

Archivo → **Guardar una copia en Drive** y ejecuta primero **Configuración**

Lo que te llevas del Tema 1

1 · Memorizar	**si el entrenamiento mejora y el simulacro empeora, la red está memorizando**
2 · Frenos	**dropout, aumento de datos y parar a tiempo; y el mejor freno: más datos**
3 · Robustez	**4 píxeles, un ruido invisible o un mundo que cambia pueden tumbar a un modelo exacto**

Antes del Tema 2

Lee la lectura de tendencia **«¿Puedes explicar por qué tu modelo dijo «no»? Explicabilidad, robustez y la llegada de las reglas»** (5 páginas) y responde la encuesta en Canvas.

En el Tema 2: ¿podemos aprovechar lo que otra red ya aprendió? ¿Y explicar por qué decide lo que decide?

T2

Reutilizar y explicar

¿Puedo aprovechar lo que otra red ya aprendió? ¿Y puedo explicar por qué decide lo que decide?

- Repaso del Tema 1
- Transfer learning
- Congelar o ajustar
- Pocos datos
- En la vida real
- Por qué explicar
- Dónde miró
- Prueba de cordura
- Explicar un crédito
- Contrafactual
- Por zona
- La IA se explica
- Las reglas
- Práctica NB06

Tema 2 · ≈ 2 h con el NB06

El Tema 1 en tres ideas

¿Quién explica cada una con sus palabras, antes de que aparezca?

1 · Memorizar	con 1 000 fotos: 96.7 % estudiando y 83.0 % en el simulacro
2 · Frenos	dropout, aumento y parar a tiempo; el mejor freno es tener más datos
3 · Robustez	ruido invisible con ε = 0.05: de 87.7 % a 39.2 %; vacunada, 71.7 %

Ahora dos preguntas nuevas: **¿y si tengo muy pocos datos?** y **¿y si me piden explicar por qué decidió?**

Transfer learning: no empezar de cero

Idea clave 4

Una red que ya aprendió a mirar prendas le presta sus «ojos» a una tarea nueva.
Solo le enseñamos la última parte.



La parte que **mira**: bordes, esquinas y formas · `4 800` números

La parte que **decide**



Ajuste fino: después se descongela todo y se entrena con **pasos 10 veces más pequeños** (`learning rate 0.0001`), para no borrar lo que sabía.

Contratar a un profesional con experiencia y darle una inducción corta

Aprende rápido, pero trae hábitos de trabajos anteriores que no conoces del todo (lectura de tendencia).

Congelar o ajustar, en código

Idea clave 4

Congelar es una línea: `trainable = False`. Ajustar es descongelar y compilar otra vez con **pasos pequeños**.

```
base = keras.Sequential(convs)   # learned: 6 other garments
base.trainable = False           # freeze its experience
model = keras.Sequential([
    keras.Input(shape=(28, 28, 1)), base,
    layers.Dense(4, activation="softmax")])   # new head
model.compile("adam", "sparse_categorical_crossentropy")
model.fit(x_few, y_few, epochs=100,
          validation_data=val, callbacks=[stop])
base.trainable = True            # fine-tuning: unfreeze
model.compile(keras.optimizers.Adam(1e-4),   # small steps
              "sparse_categorical_crossentropy")
model.fit(x_few, y_few, epochs=40,
          validation_data=val, callbacks=[stop])
```

Congelar

usar su experiencia tal cual y enseñarle solo la última parte

Una cabeza nueva

Dense(4): 800 × 4 + 4 = 3 204 números para aprender

Ajuste fino

dejar que ajuste un poco sus hábitos, con pasos pequeños (0.0001 en vez de 0.001)

Si el paso es grande, la red **borra lo que sabía** en las primeras épocas, justo cuando hay pocos datos.

Con pocos datos, la experiencia vale

Idea clave 4

Las 4 prendas de arriba con **5, 20 o 100 fotos por clase** para estudiar. Examen final: 4 000 fotos.



La experiencia heredada ayuda **mucho con muy pocos datos** (+15 puntos con 5 fotos por clase) y **casi nada con suficientes**: con 100, desde cero ya empata.

En la vida real: redes que ya vieron millones

Pocas organizaciones entrenan desde cero: parten de un modelo que entrenó otra empresa y lo ajustan.

Las redes ya entrenadas

`keras.applications` trae CNN entrenadas con **ImageNet**, más de un millón de fotos en 1 000 clases: MobileNetV2, ResNet50…

Para textos

Se parte de un modelo de lenguaje ya entrenado. Con **LoRA** se ajusta solo una pequeña parte de él (Hu et al., 2022).

La herencia

Ahorra datos, cómputo y tiempo, pero puede traer **sesgos o puntos ciegos** de datos que nunca vimos.

```
base = keras.applications.MobileNetV2(
    weights="imagenet", include_top=False, input_shape=(224, 224, 3))
base.trainable = False                    # the same two ideas
```

Debate de la lectura

Reutilizar o entender: el transfer learning ahorra recursos, pero heredamos lo que no podemos auditar. ¿Dónde está el límite?

¿Por qué dijo «no»?

Una cooperativa usa una red para decidir créditos. Una socia recibe un «no» y pregunta, con todo derecho: ¿por qué? **(Datos ficticios.)**

Ingreso	**$506 al mes**
Cuota	**≈ $144 (29 % del ingreso)**
Antigüedad	**1 mes como socia**
Atrasos	**2 en los últimos 12 meses**
Garante	**no tiene**
Ahorro	**1.5 meses de ingreso**
Zona	**rural**

Probabilidad de mora: 61 % → rechazada

Ecuador · marzo de 2026

Una norma permite a las personas afectadas por decisiones automatizadas pedir **«una explicación sobre la lógica aplicada por el algoritmo»** (Lexis, 2026).

El científico de datos

necesita saber si el modelo es **correcto**: ¿mira lo que debe?

La persona afectada

necesita saber **qué puede hacer**: ¿qué tendría que cambiar?

Rara vez la misma explicación sirve para los dos. En este tema vemos herramientas para cada uno.

¿Dónde miró la red? Idea clave 5

La CNN de 10 prendas (87.7 %) y tres maneras de preguntarle qué zona de la foto influyó. Cambia de prenda y de método.



botín · la red dice botín con 96 %

botín · 96 % | camisa · 77 % | bolso · 99 %

Oclusión | Grad-CAM | Gradiente × imagen

Un mapa de calor. Usa los gradientes de la última capa convolucional (11 × 11) para pintar qué zonas empujaron hacia la respuesta (Selvaraju et al., 2017).

no influyó · influyó · influyó mucho

Son **interpretaciones** del modelo, no el modelo. Como toda interpretación, pueden equivocarse: hay que ponerlas a prueba.

La prueba de cordura

Idea clave 5

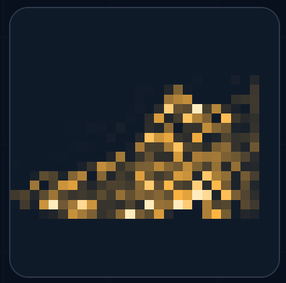
Con pesos al azar la red no sabe nada: si el mapa casi no cambia, **no la explicaba**.



La foto · botín

El traductor que sigue el tono, no las palabras

Aunque cambies el discurso, dice frases parecidas. Suena convincente, pero no traduce.

	Grad-CAM	Gradiente × imagen
Red entrenada acierta el 87.7 %		
Pesos al azar no sabe nada		
	-0.12 cambia: **pasa**	**0.90** casi igual: **no pasa**

Una explicación también tiene que **pasar pruebas**. La oclusión también pasa (–0.05).

Explicar un «no» Idea clave 5

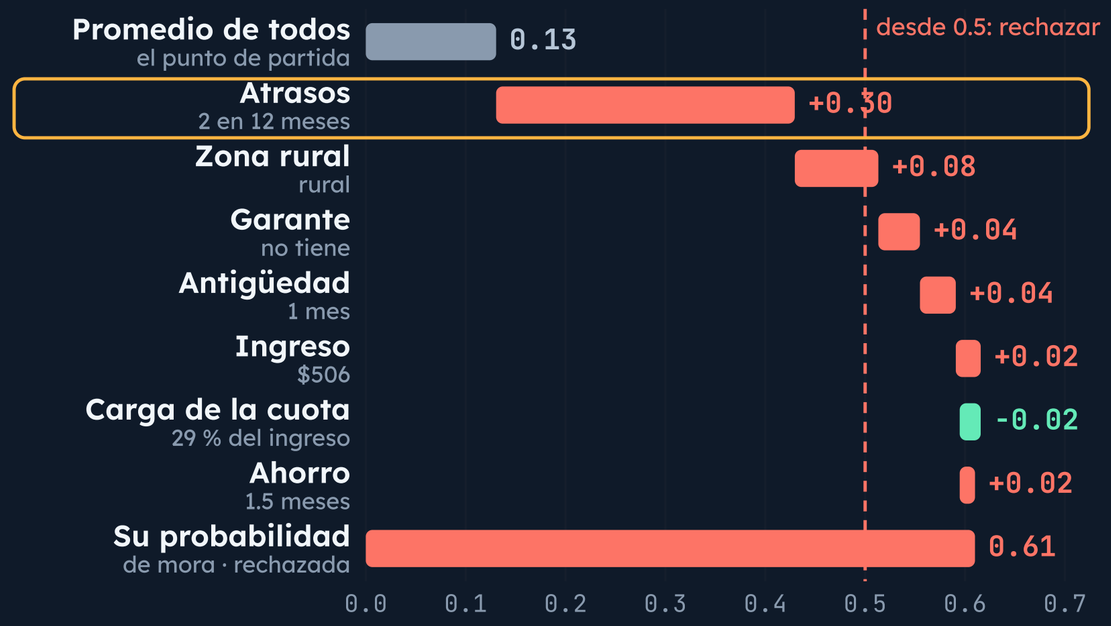
La **importancia por permutación** mira a todos los socios; **SHAP** explica una sola decisión: la de ella.

1 · En general · importancia por permutación

Cuánto baja el AUC si se mezcla esa columna en los 1 200 socios de prueba.

Carga de la cuota	0.125
Atrasos	0.051
Garante	0.049
Antigüedad	0.017
Zona rural	0.003
Ingreso	0.003
Ahorro	-0.002

2 · En su caso · SHAP reparte su probabilidad entre sus datos, como el mérito de un gol entre los jugadores



Lo que más importa **en general** (la carga de la cuota) no es lo que más pesó **en su caso** (sus 2 atrasos).

Lo que le sirve a la socia: ¿qué tendría que cambiar?

Idea clave 5

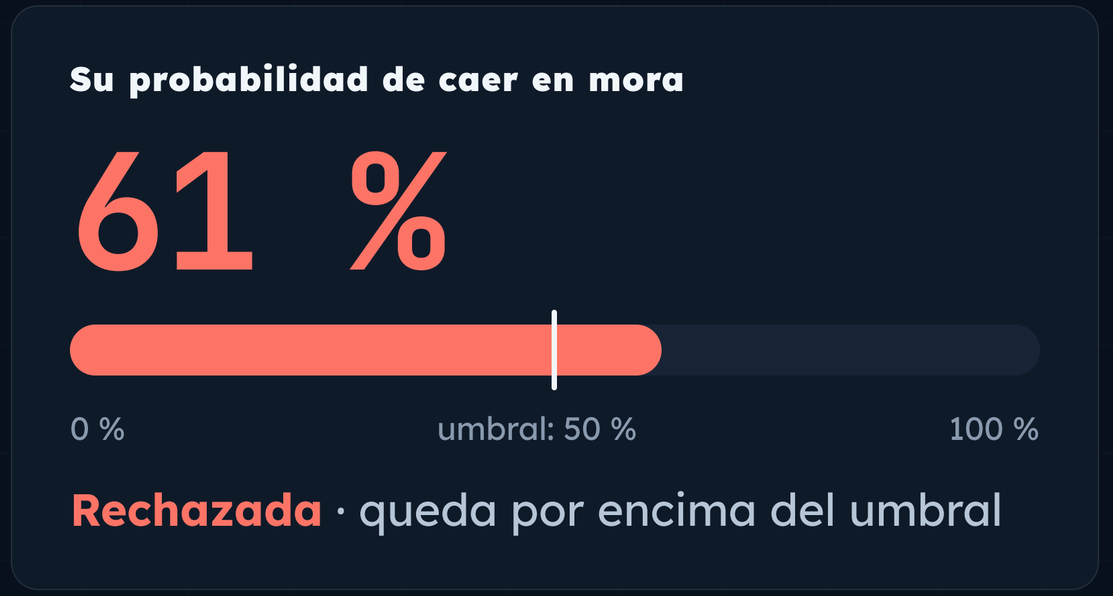
Un **contrafactual** no reparte culpas: busca el cambio más pequeño que haría cambiar la decisión. Prueba los botones.

Su caso | Sin los 2 atrasos | Cuota de $124

atrasos: 0 | 1 | 2

cuota al mes: $144

Los 3 botones son cálculos reales de la red del NB06. Los controles interpolan entre ellos: es ilustrativo.



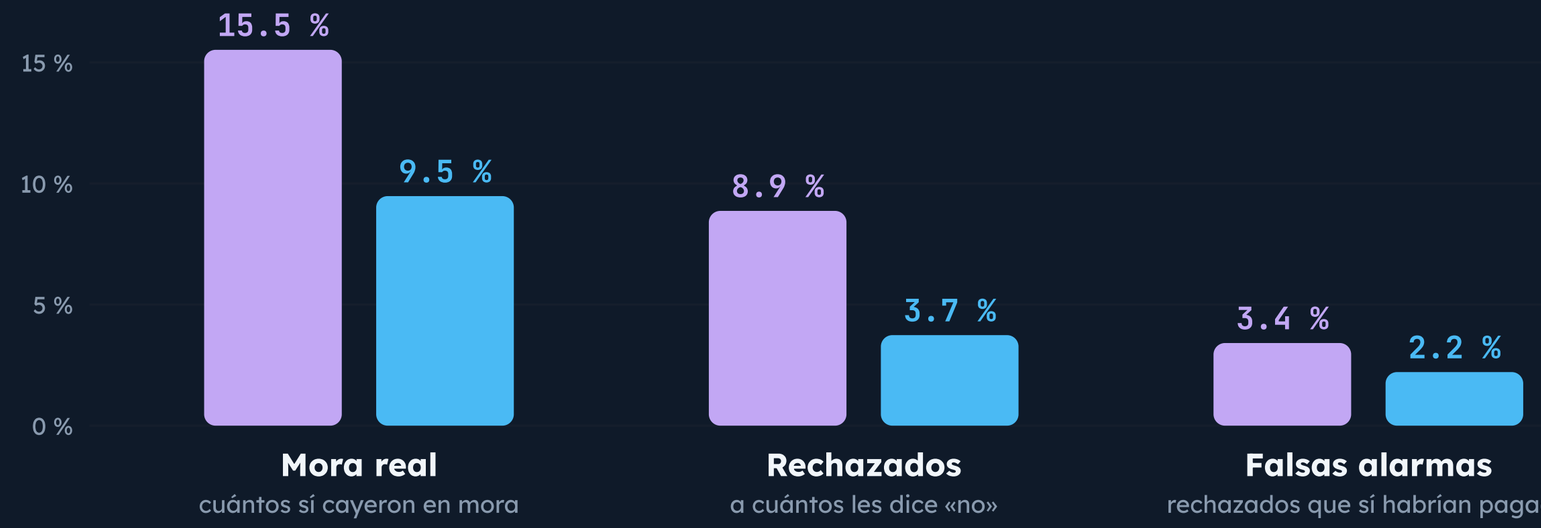
Dos respuestas que ella puede usar: **sin los 2 atrasos**, 12 %; o una cuota de unos **$124** (unos $20 menos al mes, con un plazo más largo), 48 %. Las dos la aprueban.

¿Trata a todos por igual? Idea clave 5

Los mismos 1 200 socios de prueba, separados por zona: 451 rurales y 749 urbanos.

con la columna «rural» · AUC 0.80 | **sin la columna · AUC 0.79**

rural (451 socios) urbana (749)



Quitar la columna acerca las tasas con un costo pequeño (AUC 0.80 → 0.79), pero no responde la pregunta de fondo: **¿por qué la mora real es distinta?** No hay una respuesta solo técnica.

¿Y si le preguntamos a la propia IA?

Lectura de tendencia

Un modelo de lenguaje puede explicar su respuesta con palabras. Pero esa explicación también es texto generado: no necesariamente describe lo que pasó adentro.

Mirar adentro

Ante «¿cuál es la capital del estado donde está Dallas?», un modelo de Anthropic representaba **Texas** por dentro antes de decir **Austin**. Pero el método dio una comprensión satisfactoria en cerca de **una cuarta parte** de los casos.

Lindsey et al., 2025

La explicación que suena bien

Al preguntarle cómo sumó **36 + 59**, respondió con el método escolar de «llevar uno». Por dentro hacía otra cosa: una estimación aproximada más el cálculo preciso de la última cifra.

Lindsey et al., 2025

La cadena de pensamiento

Con una pista escondida en la pregunta, la mencionaron solo el **25 %** (Claude 3.7 Sonnet) y el **39 %** (DeepSeek R1) de las veces que la usaron. Leer ese razonamiento es una oportunidad valiosa, pero «frágil».

Anthropic, 2025 · Korbak et al., 2025

Como preguntarle a alguien por qué eligió una camisa

Te dará una razón coherente, pero no siempre la que realmente influyó.

Tendencia: llegan las reglas

Lectura de tendencia

Quien use IA para decidir sobre personas deberá **explicar, documentar y permitir la revisión humana**. Lo que no está claro es si sabemos hacerlo bien.

diciembre de 2024

Brasil

El Senado aprobó el proyecto de ley 2338/2023, que clasifica los sistemas de IA según su riesgo. En octubre de 2026 seguía pendiente en la Cámara de Diputados.

Bairo Gonzalez, 2026

marzo de 2026

Ecuador

Norma para el uso de IA: evaluaciones de impacto, revisión humana de decisiones automatizadas y derecho a pedir una explicación de la lógica del algoritmo.

Lexis, 2026

julio de 2026

Unión Europea

El «Digital Omnibus» aplazó las obligaciones para la IA de alto riesgo del AI Act: del 2 de agosto de 2026 al 2 de diciembre de 2027.

Orrick, 2026

octubre de 2026

Ecuador

La Asamblea Nacional tramitaba 12 proyectos de ley sobre IA; uno propone una ley orgánica de gobernanza con derecho a recibir explicaciones.

El Diario, 2026

Debate

Interpretable o explicado. Rudin (2019): en decisiones de alto impacto, usar modelos interpretables por diseño. ¿Cuánta exactitud sacrificarías por entender?

Debate

Regular ahora o esperar. Si la ciencia de explicar todavía es inmadura, ¿explicar puede volverse un trámite sin contenido?

Práctica en clase: NB06

En clase · sin nota

40 minutos

En parejas. Todo el código ya viene escrito. Antes de cada celda, apuesta qué va a salir: en la sección 3 casi todos se equivocan.

Qué deberías ver

- **1** · Con 5 fotos por clase: desde cero **30.6 %**, congelada **45.9 %**, ajuste fino **47.2 %**
- **2** · ¿Dónde miró? Los mapas de oclusión y Grad-CAM del botín, la camisa y el bolso
- **3** · Cordura: Grad-CAM **–0.12** (pasa), gradiente × imagen **0.90** (no pasa)
- **4** · La socia: **61 %**; SHAP: atrasos **+0.30**; en general, la carga (**0.125**)
- **5** · Contrafactual: sin atrasos **12 %**; cuota de $124 → **48 %**
- **6** · Por zona: rechazo rural **8.9 %** y urbano **3.7 %**; sin la columna, **6.4 %** y **5.6 %**

deeplearningweek1.vercel.app/?nb06

Archivo → **Guardar una copia en Drive** y ejecuta primero **Configuración**

Lo que te llevas del Tema 2

4 · Transfer	**congelar y ajustar: la experiencia heredada vale mucho cuando hay pocos datos**
5 · Explicar	**oclusión, Grad-CAM y SHAP son interpretaciones: dicen dónde miró o qué pesó**
5 · Verificar	**una explicación también tiene que pasar pruebas, y servirle a quien la recibe**

En el cierre: juntamos los dos temas en una sola pregunta, la misma del entregable de la semana 1: **¿le creerías a tu red?**



¿Le creerías a tu red?

El mismo título del entregable de la semana 1. Ahora tenemos más preguntas para hacerle a un modelo antes de confiar en él.

Cinco preguntas · Tu proyecto · Quiz final · Las 3 semanas · Lo que viene

Cierre · ≈ 40 minutos con la actividad y el quiz final

Cinco preguntas antes de usar un modelo con personas

La lista de la semana. Cada pregunta viene de una de las ideas clave.

1. **¿Generaliza?** · Tema 1 · idea 1
   ¿Lo medí con datos que no vio, y miré el examen final **una sola vez**?
2. **¿Aguanta cambios?** · Tema 1 · idea 3
   Fotos movidas, ruido, otra sucursal, otra época: ¿qué pasa si el mundo cambia un poco?
3. **¿De dónde viene lo que sabe?** · Tema 2 · idea 4
   Si partí de una red ya entrenada, ¿sé con qué datos se formó?
4. **¿La explicación pasa pruebas?** · Tema 2 · idea 5
   ¿Cambia si borro lo aprendido (prueba de cordura)? ¿Mira lo que debe?
5. **¿Trata a todos por igual y le sirve a la persona?** · Tema 2 · idea 5
   ¿Cómo le va a cada grupo? ¿Puedo decirle a alguien qué tendría que cambiar?

Si alguna respuesta es «no sé», **todavía no le creas**. La exactitud es solo la primera pregunta.

Actividad: ¿le creerías a la red de tu proyecto?

15 minutos en salas · 5 de puesta en común

En salas, con tu grupo de titulación. Al final, cada grupo pega **4 líneas** en el chat, una por pregunta.

1 · Memorizar

¿Qué será su simulacro y qué su examen final? ¿Cuántos ejemplos tienen?

2 · Robustez

¿Qué cambio pequeño del mundo real podría tumbar a su modelo?

3 · Transfer

¿Partirían de una red ya entrenada? ¿Cuál, y qué saben de sus datos?

4 · Explicar

¿A quién le explicarían una decisión, y cómo comprobarían que la explicación es fiel?

Ejemplo: «Radiografías de un hospital: simulacro con pacientes de otro mes y examen con otro hospital · cambio: otra máquina de rayos X · partir de una CNN entrenada con ImageNet · Grad-CAM para el médico, verificado con una prueba de cordura».

Quiz final: ¿cuánto avanzamos? No es nota

10 preguntas tipo Kahoot. Vuelven las 5 ideas clave del pre-quiz: así vemos tu avance.

1. Abre **deeplearningweek1.vercel.app/?final3**
2. Usa **el mismo nombre** que en el pre-quiz del inicio de la semana
3. Pega tu código en el chat de Teams



deeplearningweek1.vercel.app/?final3

Las 3 semanas en un mapa

Cómo aprende una red, qué forma darle y cuándo creerle.

SEMANA 1
una neurona: pesos, suma y activación

SEMANA 1
la pérdida y el gradiente: bajar la montaña

SEMANA 1
la retropropagación y Keras

SEMANA 1
métricas: el 87 % que no vale nada

SEMANA 2
cada arquitectura es una suposición

SEMANA 2
la CNN: una lupa que recorre la foto

SEMANA 2
la RNN: una libreta que se olvida

SEMANA 2
la atención: mirar directo, a un precio

SEMANA 3
aprender no es memorizar: frenos y más datos

SEMANA 3
exacto no es robusto: 4 píxeles y un ruido

SEMANA 3
transfer learning: heredar experiencia

SEMANA 3
explicar y verificar: la prueba de cordura

Lo que viene: el cierre del curso

Semana 4

Las fechas exactas están en Canvas.

Semana 4 · sin clase en vivo

Es la semana de cierre: no hay sesiones por Teams. Todo se entrega en Canvas.

Video de conclusiones

El docente publica un video corto con lo que respondieron en la encuesta de la lectura de esta semana.

Entrega final grupal

El proyecto de los grupos de titulación (20 % de la nota). Usen las cinco preguntas del cierre como lista de control.

Para repasar, y gracias

Guía de estudio	el recorderis, los dos temas y el cierre, con ejemplos y ejercicios resueltos
Slides	estas mismas, interactivas: mueve los deslizadores en casa
NB05 y NB06	generalizar y ser robusto; reutilizar y explicar: todo escrito, para leer y experimentar
Lectura	«¿Puedes explicar por qué tu modelo dijo «no»?» y su encuesta en Canvas

deeplearningweek1.vercel.app/?guia3

Gracias