LECTURA DE TENDENCIA · SEMANA 3

¿Puedes explicar por qué tu modelo dijo «no»? Explicabilidad, robustez y la llegada de las reglas

Neural Networks: Deep Learning · Maestría en Ciencia de Datos y Máquinas de Aprendizaje · UIDE
Docente: Andrés Ordóñez-Bolaños

Imagina que una cooperativa usa un modelo de deep learning para decidir a quién aprobar un crédito. Una socia recibe un «no» y pregunta, con todo derecho: **¿por qué?** Hasta hace poco, muchas organizaciones habrían respondido «así lo decidió el sistema». En Ecuador, desde marzo de 2026, esa respuesta ya no basta: una norma permite a las personas afectadas por decisiones automatizadas pedir **«una explicación sobre la lógica aplicada por el algoritmo»** (Lexis, 2026).

Esta lectura recorre tres ideas que se cruzan en ese momento: cómo intentamos explicar redes que nadie diseñó a mano, por qué un modelo exacto puede ser frágil y qué están exigiendo las leyes en Ecuador, América Latina y Europa. La pregunta de fondo es incómoda: **cuando explicamos un modelo, ¿estamos diciendo la verdad sobre lo que hace, o solo contando una historia convincente?**

Modelos que aprendemos, no que programamos

Un programa tradicional sigue reglas escritas por una persona: «si el ingreso es menor que la cuota, rechazar». Se puede leer línea por línea. Una red neuronal, en cambio, aprende sus propias reglas a partir de ejemplos, y esas reglas quedan repartidas en millones de números. Nadie las escribió, y por eso nadie puede leerlas directamente.

A esto se suma una práctica que se volvió estándar: el **transfer learning**. Pocas organizaciones entrenan sus modelos desde cero; la mayoría parte de un modelo que ya entrenó otra empresa con enormes cantidades de datos y lo ajusta a su problema con pocos ejemplos, a veces con técnicas muy eficientes como LoRA, que modifica solo una pequeña parte del modelo (Hu et al., 2022).

> **Para entenderlo mejor.** El transfer learning es como contratar a un profesional con experiencia y darle una inducción corta sobre tu empresa. Aprende rápido, pero trae hábitos de trabajos anteriores que no conoces del todo.

Esa herencia es muy útil: ahorra datos, cómputo y tiempo. Pero también significa que el modelo puede traer sesgos o puntos ciegos aprendidos de datos que nunca vimos.

Explicar después de entrenar

Como no podemos leer las reglas de una red, usamos **métodos de explicación post hoc**: herramientas que observan el modelo ya entrenado y tratan de describir qué influyó en una decisión.

- **Grad-CAM** (Selvaraju et al., 2017) se usa en imágenes. Usa los gradientes de una CNN para medir qué zonas de la imagen influyeron más en la predicción y las colorea como un mapa de calor: si el modelo dice «neumonía», el mapa debería iluminar el pulmón, no una etiqueta del hospital en la esquina de la radiografía.
- **SHAP** (Lundberg y Lee, 2017) se usa mucho con datos tabulares. Reparte el resultado entre las variables, como se repartiría el mérito de un gol entre los jugadores que participaron en la jugada: «los atrasos previos empujaron hacia rechazar; el ingreso y la antigüedad, hacia aprobar».

Estas herramientas son valiosas y las usamos en la semana 3. Pero tienen una limitación de fondo: **son una interpretación del modelo, no el modelo**. Y como toda interpretación, pueden equivocarse.

Cuando la explicación no explica

En 2018, un grupo de investigadores de Google Brain propuso una prueba muy simple para los mapas de calor, a la que llamaron «prueba de cordura» (Adebayo et al., 2018). Tomaron una red entrenada, borraron lo que había aprendido reemplazando sus pesos por números al azar, y volvieron a calcular los mapas. Si un método de explicación es fiel al modelo, el mapa debería cambiar por completo, porque el modelo ya no sabe nada. Con algunos métodos populares, **el mapa casi no cambió**: seguía resaltando los bordes de la imagen, como un filtro de fotografía, sin importar lo que el modelo hubiera aprendido.

> **Para entenderlo mejor.** Es como un traductor que, aunque cambies el discurso del orador, sigue diciendo frases parecidas porque se guía por el tono de voz y no por las palabras. Suena convincente, pero no traduce.

La lección no es que haya que tirar estas herramientas, sino **verificarlas**: una explicación también debe pasar pruebas antes de presentarse como verdad.

Mirar adentro: la interpretabilidad mecanicista

Un camino más ambicioso intenta abrir la red y entender sus mecanismos internos, como un biólogo que estudia los órganos de un ser vivo. En 2025, investigadores de Anthropic analizaron por dentro uno de sus modelos de lenguaje y encontraron cosas sorprendentes (Lindsey et al., 2025):

- Ante la pregunta «¿cuál es la capital del estado donde está Dallas?», el modelo representaba internamente **Texas** como paso intermedio antes de responder «Austin». Cuando los investigadores reemplazaban esa representación por la de otro estado, la respuesta cambiaba a la capital de ese otro estado.
- Al escribir versos con rima, el modelo parecía elegir de antemano la palabra con la que terminaría la línea y luego construir la frase para llegar a ella.

Son hallazgos fascinantes, pero los propios autores advierten que su método dio una comprensión satisfactoria en **cerca de una cuarta parte** de los casos que probaron. Entender por dentro un modelo grande sigue siendo, en buena medida, un problema abierto.

¿Y si le preguntamos al propio modelo?

Los modelos de lenguaje pueden explicar sus respuestas con palabras. El problema es que esa explicación **también es texto generado por el modelo**, y no necesariamente describe lo que ocurrió

adentro.

En el mismo estudio, al preguntarle al modelo cómo había sumado 36 + 59, respondió con el método escolar de «llevar uno». Pero sus mecanismos internos mostraban otro camino: combinaba una estimación aproximada del resultado con un cálculo preciso de la última cifra (Lindsey et al., 2025). La explicación sonaba razonable, pero no era la verdadera.

Algo parecido ocurre con los modelos que muestran su «cadena de pensamiento» antes de responder. En un experimento, se les dio una pista con la respuesta correcta escondida en la pregunta. Cuando la usaron, Claude 3.7 Sonnet lo mencionó en su razonamiento solo el 25 % de las veces y DeepSeek R1 el 39 % (Anthropic, 2025). Un grupo de 41 investigadores de varios laboratorios concluyó que leer ese razonamiento es una oportunidad valiosa para supervisar los modelos, pero una oportunidad «frágil» (Korbak et al., 2025).

> **Para entenderlo mejor.** Pedirle a un modelo que explique su respuesta se parece a preguntarle a alguien por qué eligió una camisa. Te dará una razón coherente, pero no siempre la que realmente influyó.

Exacto no es lo mismo que robusto

La explicabilidad tiene una hermana que suele olvidarse: la **robustez**. En 2015, Goodfellow, Shlens y Szegedy mostraron que basta con alterar los píxeles de una imagen de forma imperceptible para que una red la clasifique mal con total seguridad. Son los llamados **ejemplos adversariales**.

En la práctica, el riesgo más común es más silencioso: **el mundo cambia**. Un modelo de crédito entrenado con socios urbanos puede fallar con socios rurales; uno entrenado antes de una crisis económica puede fallar después de ella. El modelo no avisa: sigue respondiendo con la misma seguridad. Por eso, una explicación de un modelo que no generaliza puede terminar siendo, simplemente, **una explicación muy clara de un error**.

La tendencia: llegan las reglas

Mientras la ciencia avanza, los gobiernos empezaron a exigir explicaciones:

Cuándo	Dónde	Qué pasó
diciembre de 2024	Brasil	El Senado aprobó el proyecto de ley 2338/2023, que clasifica los sistemas de IA según su riesgo. En octubre de 2026 seguía pendiente en la Cámara de Diputados (Bairo Gonzalez, 2026)
marzo de 2026	Ecuador	La Superintendencia de Protección de Datos Personales publicó una norma para el uso de IA: evaluaciones de impacto antes de usar sistemas riesgosos, revisión humana de decisiones automatizadas con efectos jurídicos y derecho a pedir una explicación de la lógica del algoritmo (Lexis, 2026)
julio de 2026	Unión Europea	El paquete «Digital Omnibus» aplazó las obligaciones para la IA de alto riesgo del AI Act, del 2 de agosto de 2026 al 2 de diciembre de 2027 (Orrick, 2026)
octubre de 2026	Ecuador	La Asamblea Nacional tramitaba 12 proyectos de ley sobre IA; uno de ellos propone una ley orgánica de gobernanza que incluye el derecho a recibir explicaciones (El Diario, 2026)

La dirección es clara: quien use IA para decidir sobre personas deberá **explicar, documentar y permitir la revisión humana**. Lo que todavía no está claro es si sabemos hacerlo bien. Que la Unión Europea, el bloque con la regulación más ambiciosa, haya aplazado más de un año sus obligaciones muestra lo difícil que es convertir principios como «transparencia» en requisitos técnicos verificables.

El caso de la cooperativa, otra vez

Volvamos a la socia a la que le negaron el crédito. Con la norma ecuatoriana, la cooperativa debería poder revisar la decisión con una persona y explicarle la lógica del algoritmo. Un análisis SHAP podría decir que los atrasos previos pesaron más que el ingreso. Es un buen comienzo, pero quedan preguntas abiertas:

- ¿Esa explicación es **fiel** al modelo, o pasaría una prueba de cordura?
- ¿Le sirve a la socia? A ella no le interesa la contribución de cada variable, sino **qué tendría que cambiar** para ser aprobada.
- Si el modelo se ajustó a partir de otro preentrenado, ¿alguien sabe qué datos lo formaron?

Una explicación tiene, en realidad, dos destinatarios: el científico de datos, que necesita saber si el modelo es correcto, y la persona afectada, que necesita saber qué puede hacer. Rara vez la misma explicación sirve para los dos.

Debates abiertos

- **Interpretable o explicado.** La investigadora Cynthia Rudin (2019) sostiene que, en decisiones de alto impacto, hay que usar modelos interpretables por diseño en lugar de explicar cajas negras después. Otros responden que los modelos profundos son más exactos y que basta con explicarlos bien. ¿Cuánta exactitud estarías dispuesto a sacrificar por entender un modelo?
- **Explicación o verdad.** Una explicación clara genera confianza y permite reclamar. Pero si no refleja lo que el modelo calcula, genera una confianza falsa.
- **Regular ahora o esperar.** Ecuador ya protege a las personas frente a decisiones automatizadas. Si la ciencia de explicar todavía es inmadura, ¿corremos el riesgo de que explicar se convierta en un trámite sin contenido?
- **Reutilizar o entender.** El transfer learning ahorra recursos, pero heredamos lo que no podemos auditar. ¿Dónde está el límite?

Para cerrar

Hace pocos años, la pregunta en deep learning era «¿qué tan exacto es mi modelo?». Hoy se suman otras dos, igual de importantes: **¿por qué decide lo que decide?** y **¿seguirá funcionando cuando el mundo cambie?** Las herramientas para responderlas existen y mejoran rápido, pero no son infalibles: también hay que ponerlas a prueba. En un país donde ya existe el derecho a pedir una explicación, saber explicar un modelo, y saber cuándo una explicación no es confiable, deja de ser un tema académico y se convierte en parte del oficio.

Para profundizar

- Lindsey et al. (2025): las figuras interactivas del ejemplo Dallas, Texas, Austin se entienden sin matemáticas avanzadas.
- Rudin (2019): un argumento claro y polémico a favor de los modelos interpretables en decisiones de alto impacto.
- Adebayo et al. (2018): basta con mirar la figura principal para entender la prueba de cordura.

Referencias

Adebayo, J., Gilmer, J., Muelly, M., Goodfellow, I., Hardt, M., y Kim, B. (2018). Sanity checks for saliency maps. En *Advances in Neural Information Processing Systems 31* (pp. 9505–9515). https://papers.nips.cc/paper/8160-sanity-checks-for-saliency-maps

Anthropic. (2025, 3 de abril). *Reasoning models don't always say what they think*. https://www.anthropic.com/research/reasoning-models-dont-say-think

Bairo Gonzalez. (2026, 4 de octubre). *Bill 2338/2023: Where Brazil's AI legal framework stands in 2026*. https://bairogonzalez.com/en/in-the-world/ia/pl-2338-brazil-ai-legal-framework-2026/

El Diario. (2026, 11 de octubre). *Ecuador busca definir reglas para el uso de la inteligencia artificial: estas son las propuestas de ley*. https://www.eldiario.ec/ecuador/ecuador-reglas-leyes-inteligencia-artificial-11102026/

Goodfellow, I. J., Shlens, J., y Szegedy, C. (2015). Explaining and harnessing adversarial examples. En *International Conference on Learning Representations (ICLR 2015)*. https://arxiv.org/abs/1412.6572

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., y Chen, W. (2022). LoRA: Low-rank adaptation of large language models. En *International Conference on Learning Representations (ICLR 2022)*. https://arxiv.org/abs/2106.09685

Korbak, T., Balesni, M., Barnes, E., Bengio, Y., y otros. (2025). *Chain of thought monitorability: A new and fragile opportunity for AI safety* [Preprint]. arXiv. https://arxiv.org/abs/2507.11473

Lexis. (2026). *Registro Oficial del día: Superintendencia de Protección de Datos expide norma para el uso de inteligencia artificial*. https://www.lexis.com.ec/noticias/registro-oficial-del-dia-superintendencia-de-proteccion-de-datos-expide-norma-para-el-uso-de-inteligencia-artificial

Lindsey, J., Gurnee, W., Ameisen, E., Chen, B., Pearce, A., y otros. (2025, 27 de marzo). On the biology of a large language model. *Transformer Circuits Thread*. https://transformer-circuits.pub/2025/attribution-graphs/biology.html

Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. En *Advances in Neural Information Processing Systems 30* (pp. 4765–4774). https://arxiv.org/abs/1705.07874

Orrick. (2026, 29 de julio). *EU AI Act update: Digital Omnibus finalizes 8 compliance changes*. https://www.orrick.com/en/Insights/2026/07/EU-AI-Act-Update-Digital-Omnibus-Finalizes-8-Compliance-Changes

Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence, 1*(5), 206–215. https://doi.org/10.1038/s42256-019-0048-x

Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., y Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. En *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (pp. 618–626). https://arxiv.org/abs/1610.02391

Superintendencia de Protección de Datos Personales. (2026). *Norma general para la garantía del derecho de protección de datos personales en el uso de sistemas de inteligencia artificial* (Resolución SPDP-SPD-2026-0009-R). Registro Oficial n.º 240, 10 de marzo de 2026.